

学校代号 10532

学 号 S2010W0883

分 类 号 TP391

密 级 公 开



湖南大学
HUNAN UNIVERSITY

硕士学位论文

基于模糊理论的智能交通认知模型 可解释性研究

学位申请人姓名 钱欣姣

培 养 单 位 信息科学与工程学院

导师姓名及职称 安吉尧 教授 姚敏江 高工

学 科 专 业 计算机技术

研 究 方 向 深度学习模型与技术

论文提交日期 2023 年 4 月 20 日

学校代号：10532

学 号：S2010W0883

密 级：公开

湖南大学专业硕士学位论文

基于模糊理论的智能交通认知模型可 解释性研究

学位申请人姓名： 钱欣姣

导师姓名及职称： 安吉尧 教授 姚敏江 高工

培 养 单 位： 信息科学与工程学院

专 业 名 称： 计算机技术

论文提交日期： 2023 年 4 月 20 日

论文答辩日期： 2023 年 5 月 11 日

答辩委员会主席： 谢鲲 教授

Research on The Interpretability of Intelligent Traffic Cognitive Models Based on Fuzzy Theory

by

Qian xinjiao

B.E. (Zhengzhou University) 2020

A thesis submitted in partial satisfaction of the

Requirements for the degree of

Electronic Information

in

Computer Technology

in the

Graduate School

of

Hunan University

Supervisor

Professor An Jiyao

Senior Engineer Yao Minjiang

April, 2023

湖 南 大 学

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果作品。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

作者签名：

日期： 年 月 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权湖南大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于

1、保密□，在_____年解密后适用本授权书。

2、不保密☑。

（请在以上相应方框内打“√”）

作者签名：

日期： 年 月 日

导师签名：

日期： 年 月 日

摘 要

智能交通系统是一套集成了信息技术、传感器技术、控制技术、统计学、调度算法等多种技术为一体的综合运输系统。随着大数据和人工智能技术的飞速发展,智能交通系统也逐渐从感知智能转向了认知智能,相关领域的各类深度学习模型也层出不穷。但在今天,要想将这些方法应用于实际的智能交通系统,还有很多障碍需要跨越,比如深度学习模型的黑盒特性以及交通场景中外部属性对交通认知的影响等。深度学习模型的黑盒特性使得其决策过程复杂且不可解释,这不符合智能交通系统对认知模型的高安全性要求。另外,外部属性是交通认知过程中不容忽视的重要影响因素,例如天气、假期信息、周边建筑等都对交通状况有很大影响。针对外部属性影响分析问题,从解决交通数据时空特性提取困难、外部属性影响特征难以挖掘、深度学习模型黑盒特性、外部属性影响分析等问题出发,本文研究了相关数据处理、交通认知、外部属性影响分析等三个重要工作:

1) 构建了一种基于模糊理论的外部属性数据处理方法,该方法解决了外部属性数据格式不统一,表示形式语义化的问题。引入了图模型以解决交通场景的建模问题,将交通场景中的主干道路建模成图模型中的节点,图的有向边用于表示不同道路之间的连接关系。为了获得易懂且可解释的外部属性影响分析结果,本研究使用模糊隶属度函数处理交通认知结果。

2) 提出了一种基于模糊理论的交通认知深度学习模型,该模型由基于模糊理论的模糊推理机制、基于图卷积的空间特性提取模块以及基于门控循环单元的时间特性提取模块组成。基于模糊理论的模糊推理机制可以有效地提取外部属性的影响特性,其中的模糊规则不仅可以指导模型的决策过程还能提高模型整体的可解释性。基于图卷积的空间特性提取模块,其中的对称归一化拉普拉斯算子引入了度矩阵来解决道路节点自传递的问题,并且归一化后的邻接矩阵也解决了相邻道路节点间影响较大的问题。这类神经网络,可以很好的捕获道路节点间的空间依赖特性。另外,门控循环单元可以控制信息的更新和已存储信息的重置,相比于其他循环神经网络来说,门控循环单元结构相对简单其性能也能达到预期。门控循环单元的引入解决了道路节点间的时间依赖特性提取问题。

3) 设计了一种基于模糊理论的外部属性影响分析算法。为了在交通认知过程中分析外部属性的影响作用,基于前述工作成果,本研究再一次引入模糊理论,提供了可解释的外部属性影响分析。另外通过决定系数、决定系数增长率、决定系数增长率的归一化值等概念,建立了外部属性与交通认知结果之间的联系,让外部属性影响分析这一过程可以实时地进行。同时利用模糊隶属度函数对属性影

响的描述能力,将外部属性对交通认知的影响进行了分类,让分析结果一目了然。

关键词：智能交通系统；交通认知；模糊理论；图卷积神经网络；门控循环单元；
外部属性影响分析

Abstract

Intelligent transportation system is a comprehensive transportation system integrates various technologies such as information technology, sensor technology, control technology, statistics, and scheduling algorithms. With the rapid development of big data and artificial intelligence technology, intelligent transportation systems are gradually shifting from perceptual intelligence to cognitive intelligence, and various types of deep learning models in related fields have emerged. However, to this day, there are still many obstacles that need to be overcome to apply these methods to truly intelligent transportation systems, such as the black-box characteristics of deep learning models and the impact of external attributes in traffic scenes on traffic cognition. The black-box nature of deep learning models makes their decision-making process complex and uninterpretable, which cannot meet the high safety requirements of intelligent transportation systems for cognitive models. In addition, external attributes are important influencing factors that cannot be ignored in the process of traffic cognition, such as weather, holiday information, and surrounding buildings, which have a significant impact on traffic conditions. In order to solve the problem of external attribute impact analysis, this article starts with solving the difficulties of extracting spatio-temporal features from traffic data, mining external attribute impact features, black box features of deep learning models, and external attribute impact analysis.

1) A fuzzy theory based external attribute data processing method has been constructed to solve the problems of inconsistent format and semantic representation of external attribute data. Introducing a graph to solve the modeling problem of traffic scenes, where the main roads in the traffic scenes are modeled as nodes in the graph model, and the directed edges of the graph are used to represent the connection relationships between different roads. In order to obtain understandable and interpretable results of external attribute impact analysis, this study uses fuzzy membership functions to process traffic cognition results.

2) A deep learning model of traffic cognition based on fuzzy theory is proposed, which consists of a fuzzy inference mechanism based on fuzzy theory, a spatial feature extraction module based on graph convolution, and a temporal feature extraction module based on gated recurrent units. The fuzzy inference mechanism

based on fuzzy theory can effectively extract the influence characteristics of external attributes, and the fuzzy rules can not only guide the decision-making process of the model, but also improve the overall interpretability of the model. The spatial attribute extraction module based on graph convolution, in which the degree matrix is introduced by the symmetric normalized Laplace operator to solve the problem of self-transmission of road nodes, and the normalized adjacency matrix also solves the problem of large influence between neighboring road nodes. This type of neural network can effectively capture the spatial dependency features between road nodes. In addition, the gated recurrent unit can control the update of information and the reset of stored information, and compared to other recursive neural networks, the performance of the gated recurrent unit is relatively simple. The introduction of gated recurrent unit solves the problem of extracting time dependent features between road nodes.

3) Designed an external attribute impact analysis algorithm based on fuzzy theory. In order to analyze the impact of external attributes on the process of traffic cognition, this study, based on previous work, reintroduces fuzzy theory to provide interpretable analysis of the impact of external attributes. In addition, the relationship between external attributes and traffic cognitive results can be established through the concepts of determination coefficient, determination coefficient growth rate, and normalization value of determination coefficient growth rate, thus enabling real-time analysis of the impact of external attribute. Moreover, the ability to use fuzzy membership functions to describe the impact of external attributes on traffic cognition was classified, so that the analysis results clear at a glance.

Key Words: Intelligent Transportation System (ITS); Traffic cognition; Fuzzy theory; Graph convolutional neural network; Gated recurrent unit; External attribute influence analysis

目 录

学位论文原创性声明	I
学位论文版权使用授权书	I
摘 要	II
Abstract	IV
目 录	VI
插图索引	VIII
附表索引	IX
第 1 章 绪论	1
1.1 研究背景和意义	1
1.2 国内外研究现状	2
1.2.1 智能交通认知相关研究	2
1.2.2 面向深度学习模型的可解释性研究	6
1.2.3 融合模糊推理的深度学习模型	9
1.3 本文主要研究内容	10
1.4 本文组织结构	13
第 2 章 相关理论基础	14
2.1 深度神经网络	14
2.1.1 卷积神经网络	14
2.1.2 循环神经网络	16
2.2 可解释深度学习模型	18
2.2.1 数据驱动解释方法	18
2.2.2 知识感知解释方法	19
2.3 模糊推理机制	19
2.3.1 模糊理论及其可解释性	20
2.3.2 模糊规则构建	22
2.4 本章小结	22
第 3 章 各模块的数据处理方法	24
3.1 外部属性数据	24
3.2 邻接张量	25
3.3 交通拥堵指数	26
3.4 交通认知相关数据	27

3.5 外部属性影响模糊分类	28
3.6 本章小结	29
第 4 章 基于模糊理论的智能交通认知深度学习模型	30
4.1 交通认知深度学习模型	30
4.2 可解释的模糊推理机制	32
4.3 图卷积神经网络	33
4.4 门控循环网络	34
4.5 交通认知实验过程	36
4.5.1 实验数据集	36
4.5.2 交通认知评价指标	37
4.5.3 模型参数设置和调整	38
4.5.4 交通认知模型输入敏感性验证实验	41
4.5.5 对比实验分析	42
4.5.6 认知结果可视化	44
4.6 本章小结	46
第 5 章 智能交通认知应用的模糊机制与可解释方法	47
5.1 交通认知应用可解释算法	47
5.2 交通认知应用隶属度函数	48
5.3 交通认知应用实验分析	48
5.3.1 属性影响评价指标	49
5.3.2 数据集和实验部署	49
5.3.3 实验分析	50
5.4 本章小结	52
结 论	53
参考文献	56
附录 A (攻读硕士学位期间发表的学术论文目录)	67
附录 B (攻读硕士学位期间参与项目目录)	68
致 谢	69

插图索引

图 1.1 本文研究内容.....	11
图 1.2 本文核心要点.....	13
图 2.1 计算机视觉中卷积网络用于特征提取的例子	14
图 2.2 循环神经网络的展开形式	16
图 2.3 模糊推理机制的简单示意图	20
图 3.1 交通拥堵指数与交通状况之间的关系	27
图 4.1 交通认知深度学习模型整体结构.....	30
图 4.2 模糊推理过程的网络示意图	33
图 4.3 基于真实路网情况构建邻接矩阵以及度矩阵	34
图 4.4 门控循环单元基本结构	35
图 4.5 模糊规则的 3D 可视化	39
图 4.6 均方根误差在训练周期增加时的变化	40
图 4.7 调整 GRU 隐藏单元数量的对比实验.....	40
图 4.8 调整训练数据批量大小的对比实验	40
图 4.9 调整历史数据时间步长的对比实验	41
图 4.10 预测时长为 10 分钟的数据可视化	44
图 4.11 预测时长为 30 分钟的数据可视化	45
图 4.12 预测时长为 60 分钟的数据可视化	45
图 5.1 外部属性影响隶属度函数曲线.....	51

附表索引

表 3.1 相关符号说明.....	28
表 4.1 输入敏感性验证实验结果对比.....	41
表 4.2 不同模型的预测性能对比	43
表 4.3 不同预测时长下的性能比较	43
表 4.4 一天的数据与全部数据的预测性能比较	46
表 5.1 不同外部属性输入下的2、GR、GR 的归一化值.....	51

第1章 绪论

1.1 研究背景和意义

近年来,智能交通系统(Intelligent Transportation System, ITS)正逐渐从感知智能向认知智能转变。智能交通系统通过使用道路传感器,例如感应回路、雷达、摄像头等实现感知智能,并由此获得各种各样的交通数据。智能交通认知在运输和交通管理过程中发挥着重要作用,是一类为智能交通系统提供决策帮助的研究,旨在提供更好的交通决策^[1]、提高交通运营效率^[2]、减少交通拥堵^[3]、提升驾驶者的体验感^[4]等。智能交通认知方法包括交通感知结果决策^[5]、交通流量预测^[6]、交通速度预测^[7]、交通路径规划^[8]、驾驶员行为分析^[9]、交通决策支持^[10]、交通模式分析^[11]等。研究人员通过分析推理交通数据和交通状况可以提高交通认知能力,并进一步减小智能交通系统的压力。有研究表明合理的智能交通认知可以减少交通堵塞百分之十至百分之五十、节约能源百分之五至百分之十五、减少空气污染百分之二十五以上、节约企业运营成本百分之五至百分之二十五,减少交通事故百分之三十至百分之六十^[12]。尽管现在已经有大量的关于智能交通系统的研究,但是智能交通认知及其模型的可解释性问题仍然悬而未决。这是因为现有研究较少同时考虑交通认知模型的可解释性以及外部属性对交通认知的影响,外部属性之间的内部联系也被忽略了。忽略外部属性对交通认知的影响将使得认知性能下降,模型的低可解释性也会使得认知模型在一些敏感领域例如智慧交通^[13]、交通调度和指挥^[14]、自动驾驶^[15]等的应用受到限制。

由于外部属性之间存在相互作用关系并且交通认知模型往往具有黑盒特性,因此同时考虑外部属性对智能交通认知的影响和模型的可解释性时,问题将变得更加棘手。外部因素包括天气、假期、周围建筑分布、周围人口数量、道路分布情况等,都将对智能交通认知产生很大的影响^[16],现有的很多模型仅考虑其中少数几种因素的影响并且忽略了不同外部属性之间的相互作用关系,这不足以提供很好的交通认知性能。在这基础上考虑智能交通认知模型可解释性的研究就更少了,其中的可解释性研究也大多是通过可视化技术提供的低可解释性,而非提供模型本身的可解释。

现有的很多方法都聚焦在单一的智能交通数据预测问题上,较少考虑外部属性之间的相互作用,更少有研究考虑这些模型的可解释性。为了解决以上局限性,本文建立了一个基于模糊理论的智能交通认知模型,该模型不仅考虑了外部属性对智能交通认知的影响以及不同属性之间的相互作用关系,还考虑了认知模型的可解释性。基于上述的讨论,在本文的工作中涉及以下三个问题,第一个问题是

如何表达实际的外部特征属性？第二个问题是如何捕获外部属性数据中的认知影响信息以及不同属性之间的相互作用？第三个问题是如何在深度神经网络模型中引入不确定的影响特征？

为了解决上述问题，本文利用模糊推理机制从实际交通数据中提取不确定的外部属性影响信息。模糊推理机制中的模糊规则根据智能交通领域专家的经验进行构建，以涵盖不同属性之间相互作用的所有情况。为了捕获交通数据的时空特性，本文将外部属性对交通认知的影响数据和交通数据一起输入模型中的图卷积神经网络和门控循环单元中。模型中的参数是通过反向传播算法和残差最小化策略进行调整的，训练得到的最优模型将用于更准确可靠的智能交通认知。更加详细地研究内容介绍将在 1.3 小节中展开。

1.2 国内外研究现状

本文提出的智能交通认知模型引入了深度神经网络和模糊推理机制，主要研究受到外部属性影响的智能交通认知，考虑属性之间的相互作用关系以及模型的可解释性。在介绍本文研究工作之前，我们将基于几个研究领域分别介绍其国内外研究现状，包括智能交通认知、面向深度神经网络的可解释性研究、基于模糊理论的深度学习模型。

1.2.1 智能交通认知相关研究

随着数据存储技术和互联网的蓬勃发展，各地政府以及一些运输公司所掌握的交通数据越来越多，例如滴滴和优步，每天处理的乘车订单分别高达 3000 万和 1800 万之多，每完成一个订单都会收集到相应的轨迹、速度等信息^[17]。研究人员在利用收集到的交通数据改善交通问题上开展了广泛的工作，其中智能交通认知是智能交通系统发挥交通调度作用的关键所在，由于本文旨在提出一种适用于多种智能交通认知方法的模型，本文对比较常用的智能交通认知方法包括交通分类、交通生成、交通预测的国内外研究现状进行了讨论。

(1) 交通分类

交通分类的主要工作是利用不同的方法对收集到的时空数据进行分类，根据使用的技术不同，交通分类方法又可以分为两大类，分别是传统学习方法和深度学习方法。一个重要的交通分类问题是基于给定的时空数据检测交通模式，即给定所收集的移动物体的运输信息，相应的给物体的运动进行分类。

有的传统方法利用隐马尔可夫模型，将无线信号序列作为设备的输入，以此判断设备是否在移动^[18]。有的方法利用隐马尔可夫模型将物体的移动性分为三种类型，分别是静止、行走和驾驶^[19]。很多情况下一次出行可能包含多种交通模型，因此很多研究人员会将出行任务分割成多个路段进行研究^[20,21]。还有的研究将出

行轨迹进行分段，然后利用条件随机场模型将匹配的轨迹段映射到道路网络中，通过匹配的道路信息将原始的出行轨迹分类成不同的活动，并识别出行轨迹上的一些相对重要的位置^[22]。有点研究在此启发下设计了分层的动态贝叶斯网络模型，该模型基于物体的无线信号来检测物体的活动序列，网络中较低层的推断结果将用于高层的分类决策^[23]。还有研究者提出了更加通用的模型，通过整合收集到的定位信息和基础的交通路网数据包括实时公交位置、空间公交站点信息等，构建了一种交通模式检测框架，基于这个框架，可以应用贝叶斯网络、决策树、随机森林、朴素贝叶斯和多层感知机，并以非常高的精度区分公交车、汽车和地铁等机动交通模式^[24]。

递归神经网络和卷积神经网络是研究人员常用的深度学习方法，其中卷积神经网络在提高图像分类精度方面发挥着重要作用，因此很多与图像相关的交通分类问题都是利用卷积神经网络实现的。有研究通过训练两个不同的卷积神经网络模型来对不同的路面照片进行分类，并了解不同的路面状况，这一模型有助于实现车辆控制算法的早期参数化^[25]。还有研究根据天气状况对路边视频监控数据进行分类，将监控分类成干燥、潮湿、雪等^[26]。还有的研究根据视频内容检测交通状况并将交通状况进行分类^[27]。递归神经网络则常被用于序列数据的建模，由于交通数据是时间序列数据，因此也有一些研究人员在考虑如何将递归神经网络用于交通分类问题^[28]。最开始的研究是将递归神经网络用于解决运输模式分类的问题，为此设计了基于双向长短期存储器的端到端分类框架。有的研究考虑将卷积神经网络和递归神经网络组合使用，即先利用卷积神经网络学习用于交通模式识别的特征表示，之后再使用长短期存储模型捕获特征向量上时间的相关特性^[29]。为了进一步加快学习速度并提高运输模式检测的准确性，有研究只采用了长短期存储模型之外的框架^[30,31]。为了进一步提取交通数据中的时空特性，有研究者采用门控循环单元来建模时空轨迹中普遍存在的时空相关性和不规则的时间间隔关系^[32]。

（2）交通生成

交通生成是通过模拟交通环境给其他的交通预测问题提供充足的数据。所有的交通生成工作都可以分成两大类，分别是模拟和数据生成。模拟是指基于历史观察经验模拟实际交通场景并生成一些数据，而数据生成则是生成数据以表示其他预测问题需要用到但很难得到的数据。

关于模拟的相关工作大多是研究交通环境的平台构建，首先会使用贝叶斯技术基于历史交通数据计算相关数据分布，然后利用该分布来模拟不同的交通状况。有研究者创建了一个生成移动对象的平台，利用这个平台可以实现真实交通网络与目标数据集的用户定义属性相结合^[33]。还有的研究提供一个专门的模拟器用于准备和执行流量场景的模拟，包括交通网络生成、需求生成和流量生成。有的研

究设计了一个模拟器，用来在大范围的移动性决策中模拟百万代理^[34]。

关于数据生成的研究主要分成两大类，第一类是研究如何生成单个数据以解决其他预测问题，第二类是研究时空数据的建模，通过这种建模来生成数据并用于替代实际数据，以提高真实数据使用的安全性。生成单个数据的研究有生成路线以估计从起点到目的地的出行时间，具体做法是利用 KNN 方法找到最近的历史路线，其起点和终点都和给定的起点和终点相似，通过这一方法来计算最终的出行时间。这种方法的弊端是，当历史数据过于稀疏时，KNN 方法将无法发挥作用。为了解决这个问题，有研究者提出使用生成对抗性网络来生成出行者的移动路线，设计两个具有代表性的鉴别器和生成器网络，其中的鉴别器网络的组成部分中包含了一个四层的卷积神经网络，用于捕获基本的位置特征信息^[35]。关于时空数据建模的研究有使用循环神经网络对轨迹数据进行建模，从而将轨迹编码为隐藏代码，将轨迹视为道路序列，充分利用了循环神经网络的特点来捕获序列的可变长度，研究者们同时还考虑了交通拓扑结构对道路网络的约束，进一步推进了数据生成方向的研究^[36]。

（3）交通预测

交通预测问题主要倾向于预测某些未来的交通数据，包括出行时间预测^[37,38]、出行需求预测^[39,40]、交通流量预测^[41,42]、交通速度预测^[43,44]等。根据使用方法不同可以大致分为非学习方法和学习方法，学习方法又可以进一步分为传统学习方法和深度学习方法，非学习方法包括 KNN 和历史平均值方法，这些方法还可以根据交通路网、周围环境数据、空间特征、时间特征和非线性进行分类。

出行时间预测又可以分为输入起点终点的出行时间预测和给定路线的出行时间预测。输入起点终点的出行时间预测最开始的研究是利用 KNN 技术选择一条起点终点与输入的起点终点类似的历史轨迹，最后取所有相似轨迹的平均值作为出行时间的估计值^[45]。随着深度神经网络的发展，有研究者利用多层感知器即多层全连接神经网络来估计出行时间，具体做法是首先使用多层感知器根据输入的起点和终点来估计出行距离，然后估计的出行距离和出发时间来估计出行时间^[46]。由于使用多层感知器来估计出行时间忽略了路网结构的影响，因此深度神经网络的方法被用于改进该方法^[47,48]。有研究使用残差网络来编码输入的起点和终点、路网结构、时间特性、空间特性等^[49]。在此基础上，又有研究者考虑到历史轨迹的影响，利用长短期存储器和卷积神经网络来辅助编码历史轨迹，这样设计的模型所估计的行进时间将精确的依附于出行轨迹^[50]。给定路线的出行时间预测相关研究均需考虑路网结构，最开始的研究与给定起点终点的出行时间预测一致，使用 KNN 方法选择最相似的历史子轨迹来估计出行时间，但这种方法无法处理历史数据稀疏的情况^[51]。有研究考虑到这一点后，使用三维张量对不同时间段内不同路段上不同出行者的行驶时间进行建模，然后利用上下文感知张量分解方法填

充张量的缺失值，从而解决历史数据稀疏的问题^[52]，但是这类模型也存在很大的缺点，就是无法捕获出行模式的动态特性。之后又有相关的研究采用其他的机器学习方法，如决策树、隐马尔可夫方法等，为了捕获交通数据中的时间和空间特性，更多的研究侧重于使用卷积神经网络和长短时记忆模型^[53,54]，并进一步使用递归神经网络来对整个路网以及外部属性进行编码^[55]。

出行需求预测的目的在于获得城市不同地区未来的交通需求数据。最开始有研究结合了几个传统的学习模型来提高预测的有效性^[56]。之后，人们更多的应用深度学习方法来预测出行需求问题，包括多层感知器、卷积神经网络和递归神经网络，然而这些深度学习模型往往无法捕获图形特征，为解决这一问题，研究者们使用图卷积神经网络^[57]。有研究者分别构建领域图、函数相似性图和不同区域之间的连通图，以捕获复杂的空间相关性，此外还使用递归神经网络来捕获交通数据之间的时间依赖性^[58]。

交通流量预测根据预测的范围不同，可分为区域流量预测和路网流量预测。最开始处理区域流量预测问题时，研究者们利用一些基础的学习方法的集成来实现^[59]。之后，研究者们更多的使用深度学习模型进行预测，具体做法为将整个城市路网划分成不相交的区域，并定义每个区域的流入流出，将历史交通流视为图片，每个区域对应图片中的一个像素，最后利用卷积神经网络对其进行编码^[60]。考虑到交通数据的时序特性，研究者们又应用长短时记忆模型对整个序列进行编码，以获得未来交通流量与历史交通流量之间的关联特性^[61]。路网流量预测则更侧重于研究道路交叉口的流量预测，研究者们使用到的方法包含一般的时间序列预测方法（HA、ARIMA 等）^[62,63]、传统的学习方法（主成分分析、支持向量回归等）^[64,65]以及深度学习模型（CNN、GCN、RNN 等）^[66,67]。还有些更加复杂的，将传统学习方法和深度学习方法结合使用的模型也取得了很好的预测效果^[68,69,70]。

交通速度预测即预测出行者在道路上的行驶速度，与其他交通认知问题类似，近期的相关研究大多应用了深度学习方法，而不是使用一般的时间序列预测方法或传统学习方法。有研究者考虑使用不同的深度学习模型来编码历史交通数据，其中效果比较出色的是通过合理的将卷积神经网络和递归神经网络进行整合，首先经过卷积神经网络捕获路网拓扑结构的感知特征，之后再应用门控循环单元或长短时记忆模型进一步提高模型的预测准确性^[71]。考虑到交通速度受到交通上下文、交通环境等的影响，并且具有时间特性和空间特性，后续的研究在此基础上做了进一步的研究，并取得了不错的预测效果^[72,73]。

由于交通数据的复杂程度高并且大多数真实的交通数据都不公开，导致智能交通认知的发展受到了限制，如何利用人工智能获取更多的交通数据特征是摆在研究人员面前的一大难题。现在的交通网络错综复杂，将全国乃至全世界的大部

分地区都连接在一起，构建一个统一的智能交通系统将大大地便利人们的出行甚至推动全球经济发展。

随着深度学习、交通系统感知智能、大数据等技术的飞速发展，智能交通认知相关研究已经达到了较高的水平，具体到交通预测方面，现有的智能交通认知模型已经能够达到很高的预测准确性。不足之处在于对智能交通认知模型可解释性的研究较少，而要将智能交通认知模型应用于安全系数要求较高的领域，例如自动驾驶领域，提高认知模型的可解释性是很有必要的。

1.2.2 面向深度学习模型的可解释性研究

在过去几年里，深度学习相关模型在计算机视觉、自动驾驶、生物科学、自然语言处理等其他领域，取得了优异的研究成果。随着学习模型的快速发展，越来越多的研究者关注到深度学习模型使用的安全性问题。现存的不少研究问题都可以利用深度学习模型找到解决问题的方法，所得到的实验结果甚至是研究者意想不到的^[74]。这意味着深度学习模型的潜在运行机制与人类的思考机制有很大的差异，目前这一问题也没有得到很好的解释，这一特点使得深度学习模型在许多敏感领域，例如自动驾驶、药物合成、基因组学等的应用受到限制。而深度学习模型的可解释性则是要求模型的运行机制通过某种自然语言或是逻辑规则进行表达，使得解释的语言尽可能的贴合人类的逻辑。根据提供解释的类型不同可以分为主动解释方法和被动解释方法，根据解释的范围不同，可以分为全局的可解释性和局部的可解释性，下面本文将以主动解释和被动解释作为大类，对相关的研究方法进行分类概述。

(1) 主动解释方法

主动解释方法是研究人员试图在网络模型的训练过程中增加可解释性限制，其中比较常用的方法是在模型训练过程中使用自定义的正则化项，其作用是表示可解释性损失。有研究者提出使用树正则化，通过使用浅决策化树逼近模型的处理过程，具体可以分成两个步骤，首先使用数据点训练二进制决策树，然后再计算该决策树上每个数据点到根节点的平均路径长度^[75]。由于其中的树正则化参数是不可微的，研究者又引入了替代的正则化项，方便后续模型的训练^[76]。还有研究者通过使用卷积神经网络实现模型的主动解释，研究者认为神经网络已经学习了层次结构中一些从低级到高级的表示，但是对于一些对象级概念的学习组合还是会出现混乱的情况^[77]，为此研究者考虑在层次结构的高层使用滤波器来学习组合对象级的概念^[78]。有的研究与树正则化类似的，通过在模型中添加一个可解释性的正则化器来提高局部属性的影响作用，从而实现更好的全局可解释性。这种正则化要求模型具有高保真度和稳定的局部属性^[79]。在此基础上，有研究者提出了深度归因先验方法，即在训练模型前对特征的重要性进行粗略的验证，并且还

考虑了附加属性的重要性。先验过程将与主预测模型一同训练，并且让模型具有与先验相似的属性，训练完成后通过选择器网络对特征的重要性进行排序^[80]。

（2）被动解释方法

现在的大多数深度学习模型可解释性研究都是被动的解释方法，即通过各种方法了解训练好的网络模型，包括规则、隐藏语义、归因、示例说明。

现有的研究方法侧重于利用训练的神经网络和特定的输入产生逻辑规则作为模型的解释。有研究者通过找出特征来制造局部的规则解释，所找出的特征是最有代表性，对模型预测结果影响最大的，并且由于每增加一个特征都会使得模型变得更加复杂，因此所提取的特征数量应该尽可能少^[81]。还有研究者提出对识别网络所有输入的关键数据路由路径进行处理，在 GCN 中，一个特征图的生成对应一个内核，该特征图将作为一个通道被送往下一层^[82]，这是一种局部可解释的方法。在此基础上有研究者将每个层上的输出信道加上一个非负权重，以表明该信道的重要性，通过优化权重的大小使得权重与相应信道相乘时，网络仍能得到与原始网络相同的预测结果。还可以通过提取包含一组输入的规则，而不是单个输入的规则^[83]。有研究者提出了锚，可以提供局部且十分精确的规则，该方法类似于归因方法 LIME，但是就产生的解释而言，这两种方法是不同的，LIME 是通过单个示例产生归因结果，而该方法则是基于多个示例产生的^[84]。还有的研究试图找到一些规则可以覆盖输入空间的某个子集，并且为模型提供可解释性，根据子集的大小，可以在保证模型预测精度的情况下进行低成本的替换^[85]。以上的方法均提供模型的局部解释，在很多应用场景下，我们希望对网络进行某种形式上的整体解释，而不是某一点上的局部解释。相关的研究可以分成两大类，第一类是利用网络特定信息提取规则，例如网络结构或学习的权重，被称为分解方法。由于这些方法中的许多是在深度学习时代之前开发出来的，大多是较为经典的前馈网络模型，这种模型在提取规则时，搜索空间的大小会随着属性数量和每个属性可能值的增加呈指数增长，因此该模型仅用于处理小型网络。为了能提取大型网络中的规则，有研究者考虑使用搜索策略来简化搜索过程。最早使用的搜索算法是 KT 算法，该算法首先根据输入属性对应的权重符号进行分组，分为正属性和负属性，首先搜索负属性，然后添加正属性，通过这一算法大大降低了搜索的复杂度，并进一步通过限制了先行词中属性的数量来降低搜索的复杂性^[86]。进一步的研究中还有研究者提出了提取规则的三大步骤，首先训练网络并修剪，然后离散化隐藏神经元的激活值，最后逐层提取规则并重写。另一类是将网络视为黑箱，仅用于生成经典规则学习算法的训练示例，被称为教学方法。这类方法根本上是规则或决策树等较为经典的学习问题，其规则的学习是通过神经网络示例进行的。有研究者在 NeuroLinear 框架的基础上，改进了规则提取的方法，底层实现采用贪婪顺序覆盖算法，该算法大大提高了模型的运行效率并且其精度也有所

提高^[87]。有研究在上述方法的基础上，在得到命题规则后，进一步引入最小一般化方法，得到一阶逻辑规则。还有的研究提取模糊逻辑的方法比较特殊，是从训练之后的神经网络中得到，该方法的特别之处就在于引入了隶属度函数，具有语义解释的功能^[88]。上述的全局方法大多数是在神经网络研究的早期阶段进行开发的，通常仅应用于较小的数据集，随着深度神经网络在各个领域的应用越来越深入，单个的决策树已经不太可能十分逼近深度神经网络的处理过程，故最近的研究转向了局部或半局部的可解释性。

第二种典型的被动解释方法是解释隐藏神经元或隐藏层的含义，是由一种将抽象概念与某种隐藏神经元的激活联系起来的想法促成的。现有的隐藏语义解释方法主要应用于计算机视觉领域，最直接的方法就是可视化。可视化方法的关键在于找到一个能够最大化影响某个神经元、通道或层的代表性输入，这通常称为激活最大化，实际是一个优化问题，其搜索空间是一个巨大的输入样本空间。首次将激活最大化应用于受监督的深度卷积神经网络是通过最大化一个类的分数来确定有代表性的图像^[89]。最近的研究发现，生成对抗网络在生成高分辨率真实图像方面具有强大的功能^[90]。除了可视化解释方法以外，有一些工作试图找到在内核和视觉概念之间的联系，还有的研究还分析了自然语言处理网络模型中单个神经元的意义，即通过建立网络输出和网络隐藏神经元之间的线性模型，对网络的神经元进行排序，排序的依据是线性模型权重的显著性，排序相对靠前的神经元可以通过找到激活它们的最高级属性或可视化它们输入的显著性图来获得它们的语义定义^[91]。

将输入属性特征对模型输出的影响进行分析归因是归因解释方法一大特点。这种解释是一个实值向量，通过分数的符号和大小来指示特征属性的重要性。但是当网络模型较复杂时很难下结论说某个像素部分对模型输出总是有相似的影响作用，基于此许多方法考虑在本地进行归因。归因方法的划分方式与其他规则提取方法十分相像，模型不可知和梯度相关是该方法最主要的两大类别。某一个分类的决策可以采用梯度进行解释，这也是研究者们会优先考虑的方法，因为梯度代表损失函数变化的方向和最快增长率，另外也可以针对某个输出类别计算梯度^[92]。**LIME** 是模型不可知归因方法中极具代表性的方法之一，通过找到一个潜在的可解释模型（线性模型、决策树等）为原有的复杂深度学习模型提供局部的归因解释^[93]。

目前，面向深度神经网络的可解释性研究方法多种多样，然而如何在不降低模型实验性能的同时提高模型的可解释性仍然是研究人员需要重点解决的问题之一。另外，深度神经网络的可解释性如何结合领域知识，即将解释用专业术语进行描述，以为相关领域研究人员提供更易懂的可解释性也是很有必要的。

1.2.3 融合模糊推理的深度学习模型

深度学习模型在各大领域都表现出了强大的学习能力，吸引了大量的研究人员利用深度学习开展工作，极大的促进了人工智能的发展。随着研究的进一步展开，研究人员发现深度学习模型无法处理现实生活中一些不确定或不精确的数据。真实数据的模糊状态是普遍存在的，精确数学、概率论、随机理论都无法完全解决现实中的模糊问题，然而模糊推理系统中的一个重要概念“隶属度函数”能很好地表达事物的模糊性，研究人员考虑将深度学习模型和模糊推理系统进行结合，不仅可以有效的描述深度学习算法中的模糊性和不确定性特征，还可以有效解决计算机视觉中图像处理的边界点或低频点的问题，另外利用模糊推理中的语言变量能合理地表达自然语言中的不精确和歧义问题并为使用者提供易于理解的解释^[94]。现有的深度学习与模糊推理融合有关研究主要分成三大类，分别是 1-型模糊集与深度学习模型结合、2-型模糊集与深度学习模型结合、语言变量与深度学习模型结合。

1-型模糊集可以解决信息不确定、冗余信息块、隶属度函数边界点分类、控制过拟合等问题，不确定的数据将被分类到不同的模糊空间中，而不是使用精确但不够准确的数字表示。将 1-型模糊集的模糊逻辑与 DBN 结合使用，通过比较该方法与现有图像融合技术的实验结果可以发现，该方法具有一定的性能优势^[95]，另外研究人员发现结合 1-型模糊集的 DBN 和 RBM 能很好的应用与大数据分类和决策支持系统。结合 1-型模糊集的 CNN 和 RNN 在多模态情绪分析^[96]和短期负荷预测^[97]上有较好的性能，可以处理部分情绪或混合情绪，还能有效降低深度学习模型在学习过程中出现过拟合现象的概率。其中结合 1-型模糊集的 CNN 可以克服传统风险可操作性分析固有的不确定性，从而获取更准确的定量风险结果^[98]。结合 1-型模糊集的 RNN 具有较强的稳定性，计算成本低，推理精度高于现有的一些方法^[99]。

2-型模糊集与 1-型模糊集相比具有更高的灵活性，这是利用隶属度函数中的不确定性足迹实现的，可以更有效的表达不确定和不精确的信息。研究人员从提高 DNN 的学习性能出发，提出了一种新的模糊激活层命名为区间 2-型模糊激活层，并结合 DNN 和 2-型模糊集的优点开发了一种新的深度强化学习算法，其理论基础是 2-型模糊集，该算法可用于传感器控制，在一些复杂环境下也能灵活的发挥作用^[100]。一些基于 2-型模糊集的 RMB 的深层通用系统可用于处理控制器中未知的时变拓扑，即其无监督的时间特征可以从风速数据中获取，通过一些仿真实验证明该系统优于基于 1-型模糊集构建的系统^[101]。2-型模糊集及其模糊熵通过与 CNN 合作，能够在图像融合的过程中有效地选择低频子图像，性能优于各种最先进的融合技术，并且在性能提升方面有很大的潜力^[102]。一种新的混沌 2-型

瞬变模糊深度神经振荡网络通过结合 2-型模糊集和 RNN 模型能够有效地解决深度学习中的海量数据过度训练和死锁问题，并提出了一种新的实时递归区间 2-型模糊神经系统来识别不确定边界^[103]。

语言形式的模糊信息大多来自各领域专家，研究人员致力于使用深度学习模型有效地处理这类信息。通过将语言变量和深度学习结合使用，不仅丰富了深度学习模型的变体，也有助于自然语言处理等其他领域的发展。研究人员基于模糊集理论和深度学习的一些技术，提出了连续词袋模型，该模型与前馈神经网络类似。连续词袋模型应用于模糊信息检索时，每个文档中与查询词语对应的单词都有一个相应的隶属度^[104]。将语言变量与 RNN 模型相结合的方法有很多，如用于中文文本-语言系统的递归模糊神经网络方法、基于语言推理和 RNN 的位置边际价格预测方法、语言变量即模糊时间序列值的模糊递归神经网络方法以及用于非线性系统建模中语言变量管理的层次模糊小脑模型清晰度控制器^[105,106]。Takagi-Sugeno-Kang 模糊系统是著名的模糊分类器之一，最近的研究处理语言信息时使用了 TSK 模糊分类器，其中的模糊规则通过随机选择固定的语言术语生成，与大多数的方法相比，该方法提高了计算效率和分类精度^[107]。另外，自适应神经模糊推理系统的隶属度函数参数通过神经自适应学习方法调整，进一步针对传感器数据缺失这一经常出现在物联网生态系统中的问题，提出了一种多核学习的深度学习方法用于心脏病诊断^[108]，其基础框架是自适应的模糊推理系统，在此基础上还提出了基于语言变量的自适应模糊推理预测模型和基于 LSTM 的深度学习预测模型。

由于融合了模糊推理的深度学习方法可以处理不确定和复杂的信息，该类模型的实验性能优于模糊系统的聚类算法，特别是在图像识别领域。实际研究过程中，深度学习模型还没有普遍使用 1-型模糊集、2-型模糊集和语言变量的一些扩展，例如模糊多集、犹豫模糊集、直觉模糊集以及区间值模糊集，然而这些模糊集具有允许用户描述元素隶属度函数上的一些不确定性优势。

深度学习模型与模糊系统的融合，虽然与传统深度学习模型相比，提高了预测，分类的精度，但仍存在一些潜在的缺陷，如隶属度函数可能导致计算复杂度大大提升、模型的可解释性和准确性往往不能同时让研究人员满意、模糊推理系统的加入会使得参数数量大大增加并且很难在运算过程中确定、模糊化的数据很难处理等。

1.3 本文主要研究内容

本文以实际交通数据为研究对象，针对智能交通认知模型的构建和交通影响描述特征分析算法的设计等关键技术进行深入研究。图 1.1 为研究框架图，内容包括：

(1)针对交通认知场景特点,利用模糊理论建模外部属性间的相互作用关系,设计了一个基于模糊推理机制的属性影响特征提取框架。该框架具体包含:数据预处理算法,模糊划分,模糊规则构建,解模糊化算法。其中,数据预处理算法将形式各异的外部属性数据用特殊的实数进行代替,并将数据的大小控制在一定范围内;模糊划分是对不同类型的外部属性根据其数值大小、对交通认知的影响程度等进行划分,便于后续操作进行;模糊规则根据专家经验进行构建,即在处理外部属性相互作用关系时加入更直接的经验,更有效地提取外部属性对交通认知的影响特征;解模糊化将前面步骤处理得到的模糊值进行解模糊化得到具体的数值,即生成外部属性对交通认知的影响特征。

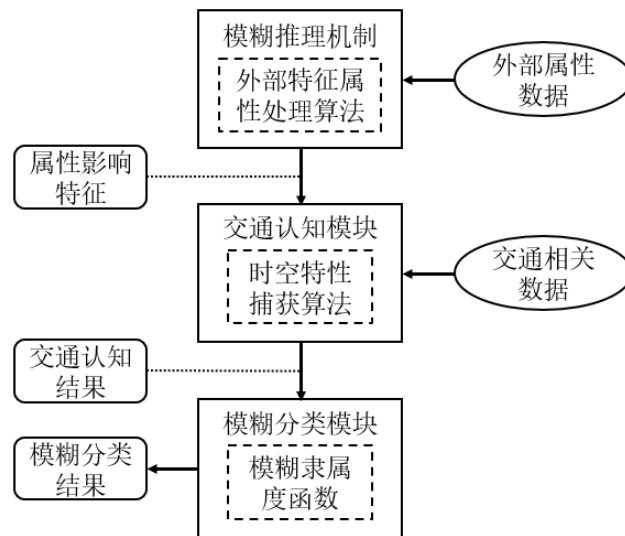


图 1.1 本文研究内容

(2)得到属性影响特征后,对交通相关数据进一步进行时空特性捕获。由于交通数据往往具有时间特性和空间特性,时间特性即前一时刻的交通数据会影响后一时刻的交通数据,空间特性即相邻道路间的交通数据会相互影响,因此如何有效捕获交通数据中的这两种特征也是本研究重点考虑的。交通认知模块包括两部分,第一部分是用于捕获空间特性的图卷积神经网络,第二部分是用于捕获时间特性的门控循环单元。由于交通路网往往可以用图来表示,图中的交通相关数据以及外部因素都会随着图的不同而产生不同的相互作用关系,因此利用图模型的特点,即考虑周边道路的影响因素来进行交通认知工作会比单一关注交通相关数据本身更有效。由于门控循环单元非常适合描述交通数据的一些时间特性,因此本文引入多个门控循环单元,建立了描述具体交通认知的量化指标,实现了基于图模型和门控循环单元的智能交通认知。

(3)为了更具体的描述外部属性对交通认知的作用关系,本研究利用模糊分类这一技术,提供了易于理解的模糊分类结果。该模块最重要的两个部分是选择合适的量化指标和模糊隶属度函数,经过实验验证最终选择决定系数作为外

部属性影响交通认知的量化指标，选择高斯隶属度函数用于模糊划分，并基于启发式地确定了阈值参数。

与上述研究内容相关的研究工作将从以下四个方面开展：

1) 建模交通场景和处理交通数据

本文将交通场景中的道路模拟成图模型中的节点，道路之间的连接关系模拟成图模型中的边。经过这样建模的关系很好的挖掘了道路与道路之间的空间交互关系，加上与交通认知相关的数据是有时间维度的，这样就模拟了具有时空特性的动态的交通场景。针对外部属性数据格式不统一的问题，本文将语义格式的数据进行数字化，并且利用模糊分类将不同类型的外部属性数据归一化在某一特定的数据范围内。针对复杂城市路网环境下的智能交通认知问题，提出一种新的智能交通认知深度学习网络模型，该模型是通过同时改进一种新型的数据处理模糊方法和捕捉城市路网的时空特性来实现和利用的，通过将与交通相关的属性分类成外部属性和交通认知相关属性，分别进行处理，可以很好的提高模型的认知性能。

2) 捕获交通数据的时空特性和外部属性的影响特性

交通数据的空间特性利用图卷积神经网络进行捕获，门控循环单元则用于捕获交通数据的时间特性。在智能交通认知模型中引入模糊推理机制，处理数据时不仅结合专家经验还考虑不同属性之间的相互作用关系，捕获外部属性之间的影响特性以及外部属性对交通认知的影响特性，更重要的是模糊推理机制的加入有助于提高智能交通认知模型整体的可解释性。

3) 在真实数据集上验证模型的可行性

通过使用中国深圳北站附近真实的城市出租车速度数据进行测试和评估，真实的实验结果可以彰显本文提出的模型与其他方法相比的优越性。此外，为了验证本文提出的图卷积网络模糊模型的可解释性，本文还利用真实的数据集测试模型在不同的外部属性数据输入下的认知性能。本文还利用美国洛杉矶高速公路上收集到的著名的 Los-loop 数据集，比较了不同预测时长下模型的预测性能，同时利用不同的预测时长来判断模型认知的稳定性。

4) 对外部属性的影响作用进行分析

由于不同外部属性的输入将对交通认知结果产生不同程度的影响，本文利用不同外部属性输入下的结果做进一步的分析，利用决定系数衡量不同外部属性对交通认知的影响，再通过模糊分类对影响程度进行划分，进一步深入交通认知工作。

相比于现有的研究工作，本研究不仅在智能交通认知过程中充分考虑外部属性对交通认知的影响，还在确保模型认知性能的情况下，提高了模型整体的可解释性。总的来说，本研究为智能交通认知做出了一定贡献且具有实际应用价值。

1.4 本文组织结构

本文分为 5 章节，核心要点如图 1.2 所示。

第 1 章绪论，依次介绍本研究相关的研究背景、研究意义以及有关技术的国内外研究现状，包括智能交通认知的研究现状、深度学习模型可解释性的研究现状和融合模糊推理的深度学习模型的研究现状。下面，概述本文的主要研究内容以及组织架构。

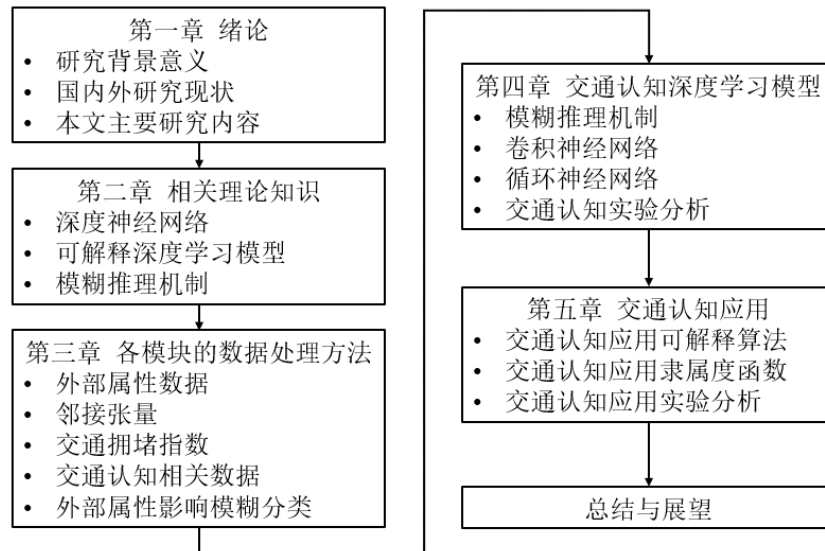


图 1.2 本文核心要点

第 2 章为相关理论基础介绍，由于本研究提出的基于模糊理论的智能交通认知可解释深度学习模型涉及深度学习理论和模糊理论，因此本章介绍了深度神经网络（包含卷积神经网络和循环神经网络）、可解释的深度学习模型（包含数据驱动解释方法和知识感知解释方法）、模糊推理机制（包含模糊理论及其可解释性和模糊规则构建）的相关理论。

第 3 章介绍各模块的数据处理方法，定义交通认知的问题，给出了外部属性数据以及交通相关数据的形式化定义，介绍如何进行外部属性影响模糊分类等。

第 4 章为基于模糊理论的智能交通认知深度学习模型，分别介绍交通认知整体模型及其不同的组成部件，具体包括可解释的模糊推理机制，图卷积神经网络，门控循环单元。最后，介绍实验相关内容并分析实验结果。

第 5 章是智能交通认知应用的模糊机制与可解释方法，在完成交通认知工作后，本文进一步利用得到的认知结果，引入模糊理论来描述外部属性对交通认知的影响，更多的考虑外部属性影响特征以及属性影响分析的可解释性。最后，分析属性影响实验结果并给出相关结论。

最后对全文进行总结，得出本文研究的结论并对本研究的不足之处进行总结和展望。

第2章 相关理论基础

深度学习模型近年来广受关注，该技术的相关应用渗入到了各大领域。通常研究人员会选用卷积神经网络处理图像类数据，而循环神经网络则常用于处理序列数据。上述两种网络中的图卷积神经网络和门控循环单元可以有效帮助解决本文研究的智能交通认知问题。另外，考虑到深度神经网络的黑盒特性以及交通场景的复杂性，引入了模糊推理机制来提高模型整体的可解释性并提取外部属性对交通认知的影响特性。下面将分别介绍有关技术。

2.1 深度神经网络

深度神经网络广泛应用于各种复杂情况的处理，如图像处理、语音处理、多维数据处理等。循环神经网络和卷积神经网络作为两种在工业应用中特别流行的深度神经网络，表现出了超强的数据处理能力。下面的章节中将详细介绍这两种网络。

2.1.1 卷积神经网络

通过控制部分发出指令使得被控制部分执行是卷积神经网络（CNN，Conventional neural networks）的根本原理。卷积神经网络作为一种人工神经网络，是应用最广泛的深度学习技术之一。卷积神经网络通常用于学习类似网格的数据中蕴含的特征，具有良好的特征生成和识别能力，在各领域尤其是视觉相关领域展示了显著的性能优势^[109]。卷积层、池化层以及全连接层是组成卷积神经网络的必要部分，特殊情况下全连接层会被全局平均池化层取代。对卷积神经网络性能影响较大的因素包括卷积层、池化层、全连接层的排列顺序以及网络的深度。下面将简要介绍这三部分的作用。




图 2.1 计算机视觉中卷积网络用于特征提取的例子

（1）卷积层

卷积神经网络中最重要的结构被称为卷积核或滤波器，卷积层往往包含多个

卷积核，卷积核的底层原理是神经元。卷积核的工作原理是将图像分割成更小块的图像，这将有助于提取特征图案，其中更小块的图像被称为接受野。为了完成卷积神经网络中相邻层的单位节点矩阵以及子节点矩阵的转换，卷积操作在设定的权重以及特定的图的基础上完成，通过将卷积核中的元素与接受野中的元素对应相乘，卷积运算表示如下：

$$f_l^k(p, q) = \sum_c \sum_{x, y} i_c(x, y) \cdot e_l^k(u, v) \quad (2.1)$$

其中 $i_c(x, y)$ 是输入张量的其中一个元素， $e_l^k(u, v)$ 是第 l 层，第 k 个卷积核， $f_l^k(p, q)$ 表示第 l 层，第 k 个卷积核输出张量中位于第 p 行，第 q 列的值。权重共享是卷积运算的一大优点，图像特征的提取可以通过在原图像上滑动相同的卷积核完成，因此相同的实验效果下，使用卷积运算可以帮助减少神经网络的参数。

（2）池化层

池化层也称为子样本层，主要作用是减少输入数据的大小。池化层最常用的实现方法有最大归并、平均归并和随机归并三种，均可以有效降低计算机的计算复杂度。池化层的上一层通常是卷积层，特征图案作为卷积运算的最终输出，可能出现在原有图像的任意位置，一旦特征被提取出来，只需保存该特征与其他特征的相对位置即可，这样既能降低模型在学习过程中出现过拟合现象的概率，也能确保较低的模型复杂度，池化层的操作则有助于提取特征的相对位置关系。池化层的底层元结构与滤波器十分相像，区别是其元结构的计算与滤波器大不相同，相比之下，池化层的计算更加简单直接，另外池化层滤波器除了在长度和宽度维度上移动外，还在深度维度上移动。

（3）全连接层

全连接层主要用于图卷积神经网络的末端，通常连接在池化层之后，进行特征分类工作。与卷积层和池化层不同的是，全连接层是一个全局性的操作，其全局性体现在当前结果包含了前面层提取到的特征，研究者可以选择合适的特征进行组合，并且组合方式是非线性的，进而实现特征分类。

图 2.1 展示了提取图像特征时选用卷积神经网络的处理过程。卷积神经网络的中间部分是完成卷积的部分，该部分主要完成两个操作，一个操作完成提取特征工作，另一个操作完成映射特征工作。 C 层为特征提取层，当前层神经元的输入数据是利用上一层的输出数据得到的，即对应的局部处理区域的输出。 S 层为特征映射层，通常同一层神经元的权重不同，当前层的所有特征都会被映射到某一个平面上，而映射在同一平面的神经元权重相同。同一个平面上的神经元具有相同的权重，是网络参数调整复杂性不高以及网络自由参数较少的主要原因，这一特点是通过特征映射层的激活函数来保证的。最后全连接层的输出即特征提取的最终结果。

从 1989 年卷积神经网络被提出至今，研究人员在参数优化、正则化、结构重构等方面对卷积神经网络进行了改造，其主要推动力在于处理单元的重组和新模块的设计^[110]。GCN 包含的种类有多路径、空间使用、宽度、深度、特征图使用、通道增强、基于注意力等，其分类标准是修改架构的方法不同。卷积神经网络主要应用于跟踪位移、图片缩放等具有失真不变特性的图形特征提取，相比于以往常用的神经网络，卷积神经网络在处理图像方面拥有同步完成提取特征和模式分类两个操作；所研究的图像与使用的网络拓扑结构更匹配；应用权值共享方法大大优化网络参数的训练等优势。

2.1.2 循环神经网络

循环神经网络（RNN，Recurrent Neural Networks）是一类有监督的机器学习模型，由带有一个或多个反馈循环的人工神经元组成^[111]。循环神经网络一般由三部分组成，分别是输入层、循环隐藏层和输出层，其中隐藏层在某一时刻的状态是以前面隐藏层的状态为条件得到的，这一特点可以使循环神经网络长时间存储、记忆和处理过去的复杂信号。

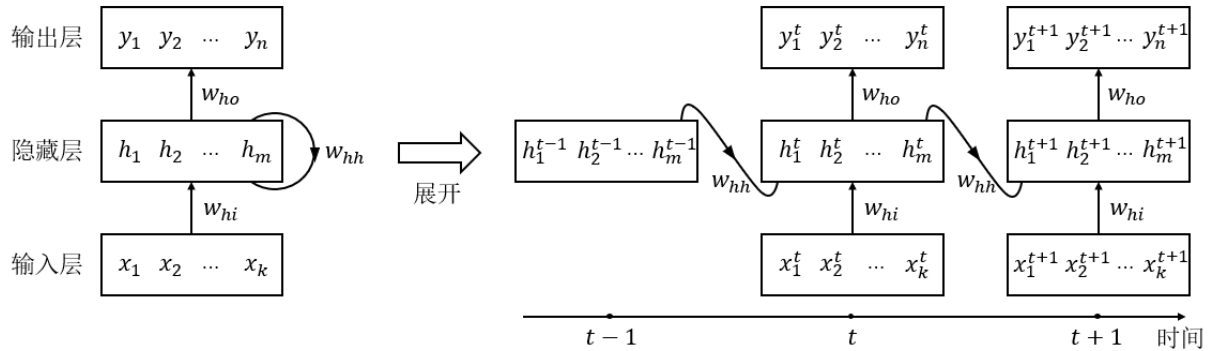


图 2.2 循环神经网络的展开形式

图 2.2 展示了循环神经网络在时刻 t 的展开形式。其中，输入层有 k 个输入单元，该层的输入是一个贯穿时刻 t 的向量序列，表示为 $\{..., X^{t-1}, X^t, X^{t+1}, ...\}$ ，其中 $X^t = (x_1^t, x_2^t, ..., x_k^t)$ 。循环神经网络的权重矩阵 W_{hi} 用于连接输入层与隐藏层中的各个神经元。隐藏层包含 m 个隐藏单元，表示为 $H^t = (h_1^t, h_2^t, ..., h_m^t)$ ，不同隐藏单元之间进行循环连接。 t 时刻隐藏层中某一神经元保存的数据状态表示为：

$$H^t = f_h(o_t) \quad (2.2)$$

其中 $f_h(\cdot)$ 表示隐藏层的激活函数，

$$o_t = W_{hi}X^t + W_{hh}H^{t-1} + b_h \quad (2.3)$$

W_{hh} 为用于连接不同层隐藏单元的权重， H^{t-1} 为隐藏层上一时刻存储的数据状态， b_h 为隐藏单元的偏置向量。权重矩阵 W_{ho} 用于连接隐藏层与输出层中的各个神经元，输出层有 n 个单元，表示为 $Y^t = (y_1^t, y_2^t, ..., y_n^t)$ ，循环神经网络最终的输出表示

为：

$$Y^t = f_o(W_{ho}H^t + b_o) \quad (2.4)$$

其中输出层使用的激活函数用 $f_o(\cdot)$ 表示，偏置向量用 b_o 表示。

上述公式表明循环神经网络是由某些非线性状态方程组成的，并且非线性状态方程的迭代是跟随时间进行的。隐藏状态在不同的时间步会根据不同的输入向量为输出层提供预测，该预测不仅提取了当前时刻输入数据的特征，还总结了网络在过去多个时间步长提取的特征，这是循环神经网络被广泛应用于序列数据预测的重要原因之一。

激活函数能够帮助丰富模型结构，提高模型推理性能，因此如何根据应用场景选择隐藏层和输出层的激活函数也是研究人员需要考虑的。近年来，比较流行的激活函数有“*tanh*”，“整流线性单元（*ReLU*）”，“*sigmoid*”等^[112]。其中“*sigmoid*”函数可将所有实数压缩至 0 到 1 的范围，该激活函数通常用于输出层。“*tanh*”激活函数实际是“*sigmoid*”激活函数的缩放形式。“*ReLU*”激活函数则仅对正输入值开放，其余值均归一化为 0。“*sigmoid*”、“*tanh*”以及“*ReLU*”激活函数分别定义如下：

$$\begin{aligned} \sigma(x) &= \frac{1}{1 + e^{-x}} \\ \tanh(x) &= \frac{e^{2x} - 1}{e^{2x} + 1} \\ y(x) &= \max(x, 0) \end{aligned} \quad (2.5)$$

“*sigmoid*”对于输出范围为 0 到 1 的网络十分适用，但由于“*sigmoid*”和“*tanh*”激活函数会让其作用的神经元饱和速度极快，可能会出现权重在梯度更新过程中表现不稳定的状况。与前面两种方法不同的是，使用“*ReLU*”激活函数会让梯度较为稀疏，这一特性可以有效地加速收敛随机梯度下降，但“*ReLU*”也存在一些缺点，例如神经元不活跃状态的时间会随着权重矩阵的增长而延长，无法很好的应对大梯度流等。

目前，比较常用的循环神经网络架构包括带有感知层的双向循环神经网络（BRNNs）^[113]、递归卷积神经网络（RCNNs）^[114]、多维递归神经网络（MDRNNs）^[115]、深度循环神经网络（DRNNs）、门控循环单元（GRU）^[116]、记忆神经网络（MemNN）^[117]、长短时记忆单元（LSTM）^[118]等。这些循环神经网络在语音识别、图像识别、视频分析、智能交通等领域的应用越来越受欢迎，但随着应用的进一步深入，有些问题还需研究人员进一步深入探究。例如梯度下降算法的引入促进了 RNN 的高效训练，同时也带来了梯度消失和梯度爆炸的问题；LSTM 和 GRU 等框架在各类应用中都显示了显著的性能优势，但与简单 RNN 相比，其内部复杂性大大提升，随之计算量也显著增加；激活稳定和激活保存等正则化方法

已经适用于 RNN，并且能有效避免过拟合，但是并没有正则化 RNN 的统一标准等。

2.2 可解释深度学习模型

深度学习模型大多建立在极其复杂的非线性函数上，例如图卷积神经网络（GCNs）^[119]、循环神经网络（RNNs）^[120]、深度信念网络（DBNs）^[121]等，这些模型的参数通常是百万甚至千万级别的。模型高度的非线性和复杂性，让研究人员很难理解其内部的工作原理及其决策过程^[122]。不透明的深度学习模型还可能引发严重的问题，阻碍模型的进一步应用。例如在自动驾驶领域，当车辆做出的预测并非人类常规判断的时候，该驾驶行为的危险系数将变得很高。因此，近年来，深度学习模型的可解释性已经成为了相关研究领域一个重要而热门的研究方向。根据模型可解释的原理不同，可以将深度学习模型的可解释方法分成两大类：数据驱动解释方法和知识感知解释方法，下面将详细介绍这两种方法的工作原理。

2.2.1 数据驱动解释方法

数据驱动的可解释深度学习模型是完全通过数据生成解释的方法，没有先验知识和外部信息的辅助。数据驱动方法通常是首先选择一个具有全局或局部分布的数据集，然后将所选的数据集或数据集变体输入到深度学习模型中，并对黑盒模型的预测结果进行分析，从而最终得到模型决策的解释。数据驱动方法的解释形式多种多样，例如通过可解释模型拟合、特征重要性分析、数据实例作为解释等。下面将介绍几种常见的数据驱动解释方法。

模型提取是数据驱动解释方法的一种，其基本思想是通过学习一个本身可解释的模型，例如线性模型和决策树，来模拟黑盒模型的决策过程。模型提取的工作过程可以分成四个步骤，第一步是选择一个和模型训练数据集具有相同分布的数据集或者直接使用模型的训练集；第二步是对数据集进行模型推理，得到对应的预测结果；第三步是选择本身可解释的模型，构造所需的模型；第四步是在选择的数据集上训练可解释模型，以拟合黑盒模型的预测结果。该方法经过几十年的发展应用，已经成为了一种有效的可解释方法，但是该方法得到的新模型通常无法达到原模型的预测精度。

基于特征的解释方法则致力于在提供解释的同时保证模型的预测精度，这一过程是通过分析输入特征的影响以及重要性实现的。该方法又可以分成两大类，第一类是捕获输入特征对模型输出的重要性，这类方法中具有最突出贡献的是 Breiman 提出的在随机森林中引入特征重要性排序^[123]，之后又有研究人员进一步深入，讨论不同特征之间的相互作用关系；第二类是激活最大化方法，该方法通

过搜索产生最大模型相应的输入模式，以此获得黑盒模型从输入数据中学习到的特征并提供解释^[124]。

基于实例的解释方法在处理图像识别等数据集为人类可理解的时，性能十分突出。该方法具体是通过选择或生成特定的数据集实例，以实现数据集的特征提取以及黑盒模型的解释。基于实例的解释方法包括原型与批评，反事实解释两大类。原型与批评中的原型是指原始数据集中具有代表性的数据实例，批评是指没有被原型集很好的表示的数据实例。反事实举例是研究者进一步认识世界、理解人类的各种行为如何作用于世界的基本方式之一，该方法是通过找到特征值的最小变化，来将模型预测结果改成所需的输出。反事实举例中实例的特征变化得越少则该反事实举例的解释效果越好。

2.2.2 知识感知解释方法

知识感知解释方法是在数据驱动解释方法的基础上，利用外部知识来丰富解释，使解释更加易于理解。非深度学习研究领域的人员可能对特征的重要性以及特征与预测结果之间的联系难以理解，当模型解释中添加了相关领域的知识，生成的解释不仅可以表明特征的重要性，还可以描述不同特征之间的关系。根据知识来源的不同，可以将知识感知解释方法分成两大类，分别是通用知识方法和知识库方法。

通用知识方法中人类参与是相对直接的一种方法，即研究人员利用知识的一般格式，提供大量人类定义的概念用于深度学习模型的预测，没有严格的逻辑规定^[125,126]。虽然这种人工参与的方法可以将外部知识投射到深度学习模型中，并产生带有领域知识的解释，但是这个过程很难自动化，特别是当相关概念过多时。知识库方法则可以很好的解决这个问题，该方法将形成一个标准、通用、尽可能完整的语料库，并导入深度学习模型中，是一种系统且结构化的解释方法^[127,128,129]。知识库方法运用知识对黑盒模型进行多个角度的解释，并建模对应的知识图，是目前比较常用的知识感知解释方法。

2.3 模糊推理机制

模糊推理机制描述的底层实现是模糊集合论，模糊推理理论的基础则是一般集合论，具体来说底层实现为一般集合论的数理逻辑通过进一步研究得到的。模糊推理机制是一类具有不确定性的推理机制，对人工智能的进一步发展极具推进作用。图 2.3 是模糊推理机制的简单示意图，本章还将详细介绍该机制的理论基础以及核心要点。

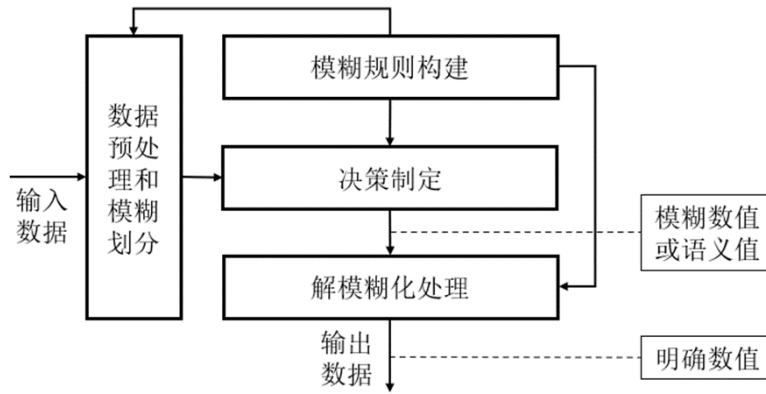


图 2.3 模糊推理机制的简单示意图

2.3.1 模糊理论及其可解释性

模糊理论（Fuzzy Theory）是一种融合了隶属度函数以及模糊集合的技术，其数学理论基础是模糊集合理论^[130]，是由扎德教授（L.A.Zadeh）在 1965 年提出来的，模糊理论的发展基础则是扎德教授在同年发表的文中首次提出的模糊隶属度函数。随着 1966 年马里诺斯（P.N.Marinos）关于模糊逻辑的研究报告以及 1974 年扎德教授关于模糊推理研究报告的发表，模糊理论成了研究人员的研究热点^[131]。现有研究逐渐深入，越来越多和模糊理论相关的应用也逐渐涌现，其中的模糊控制是一种应用最广，使用最有效的领域，其性能在各大领域都是具有可比性的，这是传统的控制方法所无法比拟的。模糊理论的系统化模型可以分成三部分，分别是模糊化、基于模糊理论的数据处理以及解模糊化。

（1）模糊化

模糊化是一种将确定类型的模型输入值转化为与之对应的模糊语言变量值的处理过程，是模糊推理过程中的一个重要环节。由于模糊推理运算的输入需要模糊值，所以在进行该操作之前一般会进行模糊化，另外，选用模糊化方法时需要慎重考虑，往往选用与数据特点以及模糊推理方法相匹配的方法。模糊化方法比较常用的包括单点的模糊集合法、输入点的隶属度取一法、隶属度值法、以及分档模糊集法等。

分档模糊集法对模糊集上对应的精确量进行了分档，不同的档次对应不同的模糊集合。用于分档的标准是隶属度值的大小，不同的隶属度值对应不同的语言值，对应到的语言值即模糊集上的精确量对应的模糊输出值。输入点隶属度取一法的处理方式分两种，第一种当模糊集合的论域为离散的整数域时，该模糊集合输入的精确量将有对应的隶属度为一的语言值，其模糊化的处理过程类似于分档模糊集法，为了提高模型处理效率，其余精确量处的隶属度值则设为 1，相邻整数点之间的精确量的隶属度值则设为 0.5；另一种方法当讨论的模糊集合论域为连续域时，输入模型的精确值经过模糊化操作后得到的模糊集合值往往呈等腰三

角形。单点形模糊集合法得到的结果是单点形的模糊集合，是通过模糊化模糊集合论域上的精确量后得到的，该模糊集合的隶属度几乎全部为零，只有一处例外，仅在这一处的隶属度为一。隶属度值法的模糊化输出结果是输入的精确量对应的语义隶属度值，该方法的表示形式可以选择连续值域上的解析表达式，这是因为该语义隶属度函数可以表示为离散值域上的表格形式，另外通常采用强度转移模糊推理法或 Mamdani 直接模糊推理法与该方法组合使用，比较特殊的是，利用组合后的方法进行模糊化，得到的不是模糊值而是精确的数值。

（2）基于模糊理论的数据处理

基于模糊理论的数据处理方法可以分成三大类，分别是模糊集表示、模糊集运算、模糊聚类分析。序偶表示法、向量表示法、以及扎德表示法是比较常用的表示模糊集合的方法，下面分别是这三种方法的定义：

$$A = \frac{A(x_1)}{x_1} + \frac{A(x_1)}{x_1} + \dots + \frac{A(x_n)}{x_n} \quad (2.6)$$

$$A = \{(x_1, A(x_1)), (x_2, A(x_2)), \dots, (x_n, A(x_n))\}$$

$$A = (A(x_1), A(x_2), \dots, A(x_n))$$

值得注意的是式中的“+”只是一个符号，并不表示常见的求和操作，“ $A(x_i)/x_i$ ”也不表示为分数，而是表示点 x_i 隶属于模糊集 A 的可能性为 $A(x_i)$ 。模糊集合的基本运算有包含、相等、并、交、余五种，预算性质基本与普通集合的运算性质相同。聚类分析方法是一种数学方法，用于按照给定的标准分类既定的研究事物。基于科学领域以及经济学领域的很多概念都没有清晰的界限这一研究背景，发展出了模糊聚类分析方法，用于解决事物之间分界模糊的问题。由于这类事物往往格式各异，因此在进行模糊聚类分析之前，需要标准化数据，即通过适当的数据变换和压缩，将具有不同性质和量纲的数据转化为模糊矩阵，使其能够适用于模糊聚类；第二步是建立模糊相似矩阵，其中最重要的是选择确定相似系数的方法，例如海明距离法、绝对值指数方法以及数量积法等；最后一步是聚类，常用的聚类方法包括直接聚类方法、布尔矩阵法以及传递闭包方法等。

（3）解模糊化

在进行模糊推理的过程中，需要利用模糊规则进行推理演算并结合演算得到的结果来获得推理输出，在输出推理结果之前，必不可少的一步就是解模糊化。解模糊化的过程具体来说就是通过输入模糊推理决策后的结果得到方便计算的精确量，即在一个输出范围内，获得一个极具代表性并且可以直接进行驱动控制的输出控制值。研究人员常用的解模糊化方法有最大隶属度法、重心法和加权平均法，这三大方法分别定义如下：

$$\begin{aligned}
 v_0 &= \max(\mu_v(v)), v \in V \\
 v_0 &= \frac{\int_V v \mu_v(v) dv}{\int_V \mu_v(v) dv} \\
 v_0 &= \frac{\sum_{i=1}^m v_i k_i}{\sum_{i=1}^m k_i}
 \end{aligned} \tag{2.7}$$

其中 v 是模糊数值或语义值， $\mu_v(v)$ 表示模糊数值隶属于某一模糊集的隶属值， k_i 表示第 i 个模糊数值对应的权重。最大隶属度法的输出值是模糊集中所有数据完成推理后能得到的最大隶属度值；横坐标与模糊隶属度函数绘制的曲线所围成图形的重心对应的是的纵坐标值即重心法的输出值；加权平均法则是取推理数据的加权平均值作为输出。*Matlab*中提供了十分方便的数据处理方法，研究人员可以根据实际应用需求进行选择。

上述介绍的三大部分构成了模糊理论的完整系统，对相关领域的进一步发展具有重要价值。模糊化、数据处理、解模糊化环环相扣，很好的体现了研究人员的思考推理过程，具有很好的可解释性。数据处理过程中构建的模糊规则就是模糊理论可解释性最直接的体现，下面还将详细介绍模糊规则的构建过程。

2.3.2 模糊规则构建

几乎所有的模糊规则都能表示为“*if a is A then b is B*”的形式，其中 A 和 B 是语言值，定义在模糊集合的论域上，模糊规则的前提可以包含多个形式类似于“*a is A*”的条件，该前提对应的结果为“*b is B*”。模糊语言变量、模糊逻辑推理以及模糊理论是模糊规则的底层实现原理，构建模糊规则的作用在于帮助模型完成模仿人类决策和推理的过程。在构建模糊规则之前需要列出描述输入输出变量的词集，这是因为在进行模糊推理时，通常使用语义中带有比较的形容词来描述输入输出变量的不同状态，例如大中小、高中低、多中少等，如果数据形式较为丰富，还可以使用表示方向的正负符号以及0状态。在实际应用中，为了方便输入输出变量在模糊规则中使用，常用变量的英文首字母作为缩写。

值得注意的是，在各种模糊推理机制中，模糊规则的表现形式并不统一，其中含有的信息量也不同，但是所有的模糊规则都可以转换成模糊规则的基本形式“*IF-THEN*”格式。模糊规则的这一特性，提供了最直接的可解释性，极大地方便了研究人员对模糊理论的研究应用。研究人员通过将相关领域的专家经验融入模糊规则中，不仅可以很好地指导模糊推理过程，也使得模糊推理机制有更高的鲁棒性。

2.4 本章小结

与本研究相关的基本模型以及基本理论知识在本章中进行了详细的介绍。本

章开始部分对本研究引入的两个基本模型卷积神经网络和循环神经网络进行了介绍，具体的包括模型结构、实现原理、该类模型在各领域的应用价值和未来的发展方向。其次介绍了可解释人工智能方法，又根据方法解释原理的不同，分成数据驱动解释方法和知识感知解释方法进行介绍。本章还介绍了模糊推理机制，其中重点介绍了与模糊推理机制相关的模糊理论以及模糊规则构建过程，由于模糊推理机制发展的尚不完备，该小节的重中之重是模糊理论的介绍。本章节为后文中各理论的实际应用奠定了基础。

第3章 各模块的数据处理方法

本章将详细介绍本文研究所使用的外部属性数据、交通相关数据的表示形式以及模型中各模块的数据处理方法。由于不同外部属性数据之间的格式差异较大，为了方便后续处理工作的进行，本研究对不同类型的数据格式进行了统一。针对外部属性之间的相互作用以及外部属性对交通认知过程的影响，本文引入了模糊推理机制，该机制一方面提取了外部属性中蕴含的复杂特性，另一方面提高了模型整体的可解释性。基于实际交通场景的特点，引入图模型描述交通路段间的相互影响，将道路建模为图模型的节点，道路之间的相互关系用图的无权边表示。考虑到交通认知过程受到交通拥堵情况的影响，本文引用了交通拥堵指数，该指数可以很好的度量交通拥堵情况，并且数据形式便于模型提取特征。本章的最后介绍了交通相关数据的表示，另外考虑到时空特性是交通数据一大特性，本研究模型应用了图卷积神经网络（GCN）和门控循环单元（GRU），并最终输出了交通认知结果。为了进一步提高交通认知，本研究对得到的交通认知结果进行了进一步的分析，并通过实验得到了不同外部属性对交通认知的影响作用。

3.1 外部属性数据

交通认知除了受交通场景以及交通数据本身的影响外，最大的影响因素就是外部属性，其中影响较大的外部属性包括交通拥堵情况、时间段信息、假期信息、天气状况、交通流量变化等。本文将外部属性的特征矩阵表示如下：

$$X_{feature} \in \{X_{TTI}, X_{time}, X_{holiday}, X_{weather}, X_{flowChange}\} \quad (3.1)$$

其中 $X_{TTI} \in \mathbb{R}^{\tau \times N}$ 为交通拥堵指数矩阵， τ 为时间步长， N 为交通场景中的道路条数，有关交通拥堵指数的知识将在 3.3 小节中详细介绍。 $X_{time} \in \mathbb{R}^{\tau \times N}$ 为时间段矩阵，矩阵中第 i 行，第 j 列的元素表示如下：

$$X_{time}^{ij} = \begin{cases} num_1, & t \in [t_1, t_2] \\ \dots & \dots \\ num_n, & t \in [t_n, t_{n+1}] \end{cases} \quad (3.2)$$

由于时间段数据比较抽象，本文根据实际交通数据的变化规律，将交通数据变化趋势相似的某一连续时间段用同一个数字表示，该方法将一天二十四小时分成了 n 个时间段。 $X_{holiday} \in \mathbb{R}^{\tau \times N}$ 为假期矩阵，矩阵中第 i 行，第 j 列的元素表示如下：

$$X_{holiday}^{ij} = \begin{cases} 1, & \text{when today is a holiday} \\ 0, & \text{else} \end{cases} \quad (3.3)$$

该式表示当假期矩阵中元素值为 1 时，当天为休息日，包括周末以及法定节日；当假期矩阵中元素值为 0 时，当天为工作日。 $X_{weather} \in \mathbb{R}^{\tau \times N}$ 为天气矩阵，矩阵中第 i 行，第 j 列的元素表示如下：

$$X_{weather}^{ij} = \begin{cases} num_1, & \text{weather condition}_1 \\ num_2, & \text{weather condition}_2 \\ \dots & \dots \\ num_m, & \text{weather condition}_m \end{cases} \quad (3.4)$$

考虑到不同的天气状况会对交通认知产生不同程度的影响，本文统计了研究时间段内的天气变化情况，并将不同的天气状况用不同的数字进行标记。式 3.4 中 m 表示研究时间段内的不同天气数量，在本文进行实验验证时 $m = 5$ ，主要包括晴天、多云、小雨、中雨、大雨五大类。 $X_{flowChange} \in \mathbb{R}^{\tau \times N}$ 为交通流量变化矩阵，矩阵中第 i 行，第 j 列的元素表示如下：

$$X_{flowChange}^{ij} = \begin{cases} num_1, & \text{flow change} \in [flow_1, flow_2] \\ num_2, & \text{flow change} \in [flow_2, flow_3] \\ \dots & \dots \\ num_k, & \text{flow change} \in [flow_k, flow_{k+1}] \end{cases} \quad (3.5)$$

上式中 k 表示研究的车流量变化区间数。一般来说车流量变化越大，对交通认知的影响越大，因此本文将影响相近的连续区间的车流量变化值用同一个数字进行标记，这样既方便数据输入模型后的特征提取，也降低了模型计算的复杂度，另外考虑到车流量增加和减少所带来的影响不同，本研究用正负符号以示区分。

为了更好地提取外部属性对交通认知的影响作用，本研究为不同的外部属性赋予不同的权重， $X_{fuzzy} \in \mathbb{R}^{\tau \times N}$ 为外部属性融合矩阵，该矩阵定义如下：

$$X_{fuzzy} = \omega_1 \cdot X_{time} + \omega_2 \cdot X_{holiday} + \omega_3 \cdot X_{weather} + \omega_4 \cdot X_{flowChange} \quad (3.6)$$

时间段矩阵、假期矩阵、天气矩阵、流量变化矩阵的权重分别为 $\omega_1, \omega_2, \omega_3, \omega_4$ ，不同属性的权重是通过控制变量法确定的，即修改某一个属性的权重并控制其余属性权重不变，观察分析实验结果，得到交通认知性能最好时候的权重。本研究涉及的符号定义已在表 3.1 中给出。

3.2 邻接张量

图作为一种常用的非线性数据结构，通常用来表示多对多的关系，在实际应用场景中可以有效地表示不同实体之间的交互关系。随着深度神经网络在交通认知领域的进一步深入研究，研究人员发现图结构可以很好的表征不同道路之间的连通关系，研究人员还可根据实际交通场景选择合适的图结构类型，包括无权图、有权图、无向图、有向图等。图结构的引入为交通认知相关研究又往前迈进了一

大步，在近些年的研究中，图已经成为了极受欢迎的交通路网表征结构，大多数的深度学习模型都是在图结构的基础上进行学习训练。

本研究采用无向图对交通中的道路进行建模，用符号表示为：

$$G = \{V, E\} \quad (3.7)$$

其中 V 为道路节点集合，表示为：

$$V = \{v_1, v_2, \dots, v_N\} \quad (3.8)$$

其中 N 为交通场景中的道路数。当某两条道路之间存在连通关系，则代表这两条道路交互关系的边就应被连接。 E 则是用来表示道路连通关系的边集合，可表示为：

$$E = \{v_i v_j | 1 \leq i \leq N, 1 \leq j \leq N\} \quad (3.9)$$

其中 v_i 代表道路节点的编号为 i ， v_j 代表道路节点的编号为 j ， $v_i v_j$ 表示第 i 条道路与第 j 条道路之间的边。邻接矩阵用来表示交通场景中研究的所有道路的连通情况，邻接矩阵中位于第 i 行，第 j 列的元素表示如下：

$$A_{ij} = \begin{cases} 1, & \text{if } edge\langle v_i, v_j \rangle \in E \\ 0, & \text{otherwise} \end{cases} \quad (3.10)$$

当道路节点 i 与道路节点 j 之间存在连通的边，则邻接矩阵中相应位置的元素为 1，否则为 0。邻接矩阵大小为 $N \times N$ ，其中 N 为交通场景中的道路条数。

3.3 交通拥堵指数

交通拥堵指数是经过时空特征、拥堵特征等多方面的考究后用于描述交通拥堵情况的数值，也被称为道路交通运行指数。交通拥堵指数的值域为 $[0,10]$ ，通过数值的高低对区域交通状况进行区别描述：交通拥堵指数位于 $[0,2]$ 区间内，表示交通运行状况为顺畅，基本没有拥堵情况；交通拥堵指数位于 $(2,4]$ 区间内，表示交通运行状况为基本顺畅，出现轻微的拥堵情况；交通拥堵指数位于 $(4,6]$ 区间内，表示交通运行状况为轻度拥堵，主干道路出现拥堵情况；交通拥堵指数位于 $(6,8]$ 区间内，表示交通运行状况为中度拥堵，主干道路大部分出现拥堵情况；交通拥堵指数位于 $(8,10]$ 区间内，表示交通运行状况为重度拥堵，大部分路段出现拥堵情况。交通拥堵指数的计算公式如下：

$$TTI = \frac{v_{free}}{v_{current}} \quad (3.11)$$

其中 v_{free} 为道路上车辆自由通行的速度， $v_{current}$ 为当前道路上车辆的平均速度。本研究将交通拥堵指数作为外部属性的一部分，用于交通认知。交通拥堵指数矩阵 $X_{TTI} \in \mathbb{R}^{\tau \times N}$ ，根据历史交通速度计算得到，其中 τ 表示时间步长， N 表示交通场景中的道路条数。

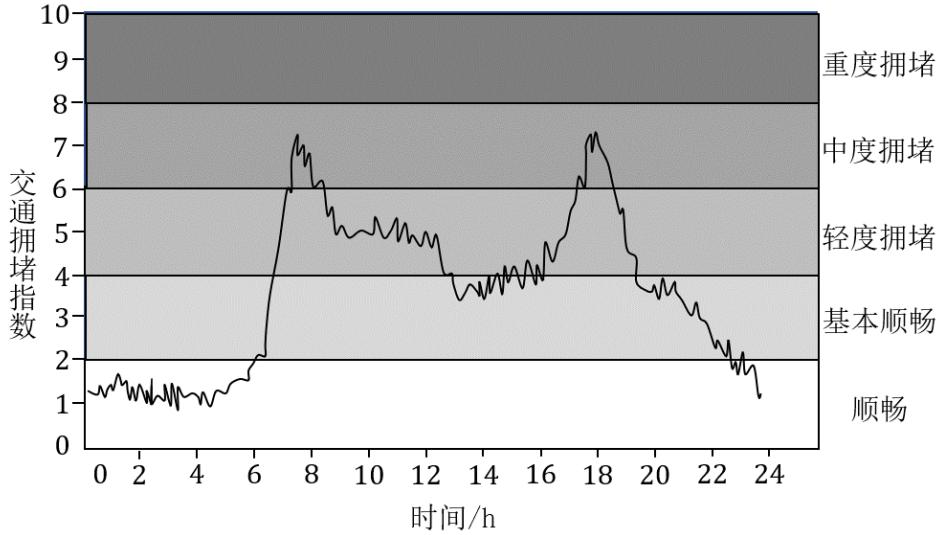


图 3.1 交通拥堵指数与交通状况之间的关系

图 3.1 为某市二十四小时内的交通拥堵指数变化情况，从图中可以很清楚地看到零点到早上六点交通运行顺畅。从早上六点到早上八点交通拥堵指数急剧增大，交通运行状况发生较大变化。交通拥堵指数的两个最大的峰值出现在上午八点左右以及下午六点左右，交通拥堵指数的最低点在下午两点左右。根据生活常识可以知道，交通拥堵指数的变化与当地人们的出行习惯有关，可以很直观的表征交通拥堵情况。

3.4 交通认知相关数据

本研究的交通认知相关数据由三部分组成，包括历史交通数据、交通拥堵相关数据以及外部属性影响数据。其中的历史交通数据可以是交通速度、交通流量、交通拥堵情况等具有时空特性的，用于描述交通场景的数据。

$X_{traffic} \in \mathbb{R}^{\tau \times N}$ 为历史交通数据矩阵，该矩阵由 τ 个历史时间步的交通数据组成：

$$X_{traffic} = [T_1, T_2, \dots, T_\tau] \quad (3.12)$$

其中 T_i 为第 i 个时间步的交通数据，表示为：

$$T_i = [t_i^1, t_i^2, \dots, t_i^N] \quad (3.13)$$

由交通场景中的 N 条道路在 i 时刻捕获到的数据组成。本研究中的交通拥堵相关数据即交通拥堵指数， $X_{TTI} \in \mathbb{R}^{\tau \times N}$ 为交通拥堵指数矩阵，矩阵中的元素是利用历史交通速度计算得到的，交通拥堵指数的大小和交通拥堵程度呈正相关。 $X_{cognition} \in \mathbb{R}^{\tau \times N}$ 为与交通认知相关的属性矩阵，是通过融合历史交通数据矩阵和交通拥堵指数矩阵得到的，其定义如下：

$$X_{cognition} = \omega_5 \cdot X_{traffic} + \omega_6 \cdot X_{TTI} \quad (3.14)$$

ω_5 ， ω_6 分别是交通数据矩阵和交通拥堵指数矩阵的权重，权重越大表示该类数据

对交通认知结果的影响越大,该权重的确定方法与外部属性权重的确定方法相似。

3.1 小节中提到的外部属性数据并不是直接和交通认知相关的数据,而是经过特殊的特征提取后才用于交通认知。 $X_{Effect} \in \mathbb{R}^{\tau \times N}$ 为外部属性影响矩阵(交通认知影响矩阵),其定义如下:

$$X_{Effect} = \prod_{j=1}^o Rule_j \left\{ \prod_{i=1}^l Exp \left[\frac{-(X_{fuzzy} - \mu_i)^2}{\sigma_i^2} \right] \right\} \quad (3.15)$$

其中 o 表示模糊规则的数量, l 表示隶属度函数的数量, μ_i 表示第 i 个隶属度函数的宽度, σ_i 表示第 i 个隶属度函数的中心。外部属性影响矩阵中的元素为有符号数,数值越大表明外部属性对交通认知的影响越大,数值的符号用于区分交通流量的增加和减少。外部属性影响特征的提取原理将在第4章节中详细介绍。

3.5 外部属性影响模糊分类

基于外部属性对交通认知的影响直接体现在本研究方法对交通数据预测准确性的影响上,本研究采用决定系数 R^2 衡量外部属性对交通认知的影响,决定系数的定义如下:

$$R^2 = 1 - \frac{\sum_{t=1}^p (Y_t - \hat{Y}_t)^2}{\sum_{t=1}^p (Y_t - \bar{Y}_t)^2} \quad (3.16)$$

其中 Y_t 为真实的交通数据, \hat{Y}_t 为本方法预测得到的交通数据, \bar{Y}_t 为真实交通数据的平均值, p 为数据总量。决定系数的值属于区间 $[0,1]$,数值越接近于1,表示模型回归拟合的效果越好,很直观的表征本研究方法在不同实验设置下的性能的同时,也方便了后续模糊分类工作的进行。

上述的决定系数可用于描述属性特征对交通数据预测的影响程度,考虑到属性影响具有三大特性,包括随机性、模糊特性及其相对主观的分类标准,为了更好的描述交通场景下的外部属性影响特征,本研究引入了模糊理论,进一步对影响特征进行分类。根据专家经验以及实际应用场景构建影响较小、影响中等、影响较大三类模糊集。具体操作将在第5章节中详细介绍。

表 3.1 相关符号说明

符号	定义
G	无向图
V	无向图 G 中的节点集合
E	无向图 G 中的边集合
A	无向图 G 中的邻接矩阵
$X_{feature}$	交通场景中的外部属性矩阵

X_{TTI}	交通拥堵指数矩阵, $X_{TTI} \in \mathbb{R}^{\tau \times N}$
X_{time}	时间段矩阵, $X_{time} \in \mathbb{R}^{\tau \times N}$
$X_{holiday}$	假期矩阵, $X_{holiday} \in \mathbb{R}^{\tau \times N}$
$X_{weather}$	天气矩阵, $X_{weather} \in \mathbb{R}^{\tau \times N}$
$X_{flowChange}$	流量变化矩阵, $X_{flowChange} \in \mathbb{R}^{\tau \times N}$
X_{fuzzy}	外部属性融合矩阵, $X_{fuzzy} \in \mathbb{R}^{\tau \times N}$
$X_{traffic}$	历史交通数据矩阵, $X_{traffic} \in \mathbb{R}^{\tau \times N}$
$X_{cognition}$	交通认知相关矩阵, $X_{cognition} \in \mathbb{R}^{\tau \times N}$
X_{Effect}	外部属性影响矩阵, $X_{Effect} \in \mathbb{R}^{\tau \times N}$
τ	预测时间步
N	交通场景中道路条数

3.6 本章小结

本章的重点在于输入数据的构造。首先详细介绍了外部属性数据的构成和邻接张量的概念。然后提出在交通认知过程中使用交通拥堵指数, 实现对交通状况的直接表征。本章详细介绍了交通认知相关数据的组成, 将交通认知数据分成了三大类, 即交通认知过程中进行特征提取的三大来源。本章最后基于模糊集理论对外部属性影响作进一步的分析, 为本研究方法在智能交通认知领域的应用提供了思路。

第4章 基于模糊理论的智能交通认知深度学习模型

在第三章相关数据结构化处理的工作基础上，本章着重介绍基于模糊理论的智能交通认知深度学习模型。近几年，随着深度学习模型的广泛应用，传统交通认知深度学习模型的预测性能已经达到了很高的水平，但是模型可解释性方面的研究却很少，考虑外部属性影响作用的研究就更少了。基于以上考虑，本研究构建了基于模糊理论的智能交通认知深度学习模型，该模型在组合使用门控循环单元和图卷积神经网络的基础上加入了模糊推理机制，有效提取交通数据中时空特性的同时，考虑了外部属性影响以及外部属性之间的相互作用关系，更重要的是模糊推理机制的加入提高了模型整体的可解释性。面对外部属性对交通认知的复杂影响关系，本研究进一步在属性影响方面进行了交通认知应用，通过对不同的外部属性输入进行实验，得到对应的预测结果并进行分析，最终基于模糊理论构建外部属性对交通认知的影响模糊分类。

4.1 交通认知深度学习模型

本节的主要目的是详细描述我们提出的基于模糊理论的智能交通认知深度学习模型。首先，我们介绍了模型的整体架构以及选择某些属性作为输入的原因。在后续小节中还将根据数据流分别介绍模型的每个模块。交通认知深度学习模型整体结构如图 4.1 所示。

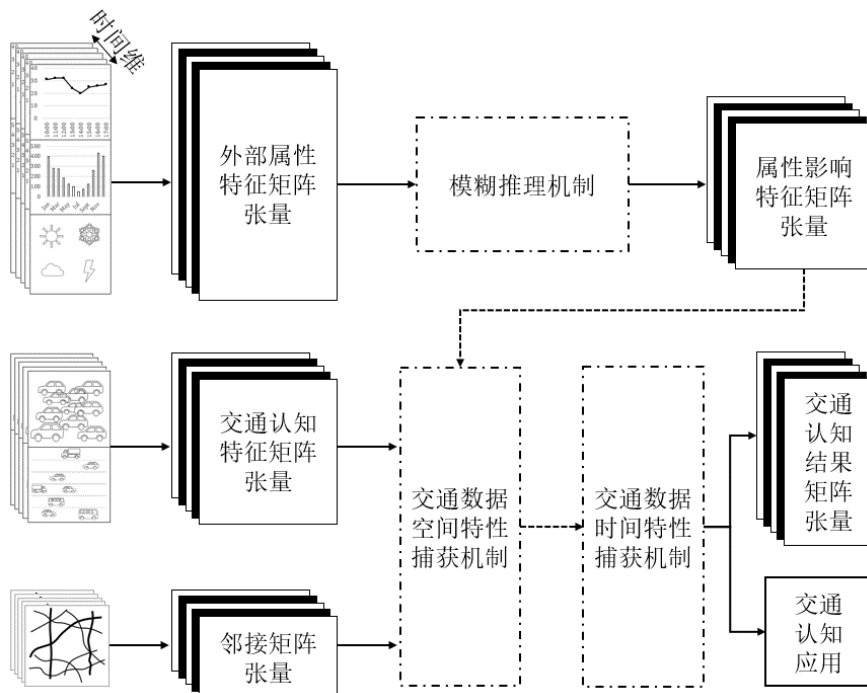


图 4.1 交通认知深度学习模型整体结构

为了弥补现有交通认知方法的不足,本文提出了一个新颖的深度学习框架用于智能交通认知。模型如图 4.1 所示,外部属性特征张量是通过融合时间段、温度、节假日、天气、周边建筑信息等外部属性获得的。此外,将外部属性特征张量输入到模糊推理机制中,获取这些外部属性对交通认知的影响值,并捕获不同属性之间的相互作用关系。同时,通过将历史交通认知数据和实时 TTI 数据融合在一起生成交通认知特征矩阵张量。交通数据的空间特征属性是利用图卷积神经网络认知交通数据特征矩阵张量、邻接矩阵张量和属性影响特征矩阵张量来进行捕获的,其中属性影响特征矩阵张量需要首先通过模糊推理机制进行处理。同样重要的是,交通认知数据中的时间特征是利用门控循环单元进行捕获的。事实上,本研究提出的模型可以应用于所有具有时空特征的数据的认知,比如交通速度预测、交通流量预测、地质检测、地址选择等。

交通数据的随机性是由于交通数据会受到外部因素的影响,考虑交通认知过程中的一些影响扰动,可以有效地提高模型的认知性能。当外部属性过少时,将无法覆盖其对交通认知的影响;当外部属性过多时,将可能重复外部属性特征提取工作,增加模型计算难度。因此,如何选择合适的外部属性作为输入,是本研究需要重点考虑的问题之一。经过调查研究以及实验验证,本文最终选取了四种主要的外部干扰属性,分别是时间段、节假日、天气和交通流量变化。通常交通数据会呈现与人们生活作息一样的周期性,即以一天为周期、以一个月为周期。用通过观察交通数据可以发现,每天的交通数据变化趋势是相似的,这是本研究选取时间段信息作为属性输入之一的原因。另外,由于交通数据会受到人们工作日和休息日的周期性的影响,我们相应的选择假期信息作为交通认知的外部属性之一。类似地,经过研究发现天气以及交通流量变化对交通数据的影响极大,因此,本研究也将这两个因素考虑进来。

交通认知总体算法如下。

- 1) 经过数据预处理,将输入数据处理成特定的形式,即外部属性特征矩阵、交通认知特征矩阵以及邻接矩阵。
- 2) 将处理后的外部属性特征矩阵张量输入模糊推理机制中进行外部属性影响特征提取,并得到外部属性影响特征矩阵张量。
- 3) 空间特征提取过程是利用图卷积神经网络处理分析外部属性影响特征矩阵张量和交通认知矩阵张量以及邻接矩阵张量完成的,然后利用门控循环单元进行提取时间特征的操作,最终输出为交通认知结果,并应用于后续的交通认知应用。

交通认知算法的伪代码总结如下:

算法1 交通认知算法

算法1 交通认知算法

Input: Feature tensor: $\mathcal{F} \in \mathbb{R}^{T \times \max_N \times C}$

Adjacency tensor: $\mathcal{A} \in \mathbb{R}^{T \times \max_N \times \max_N}$

Input:

n historical time steps fuzzy attribute: $X_{time} \in \mathbb{R}^{N \times n}, X_{holiday} \in \mathbb{R}^{N \times n},$
 $X_{weather} \in \mathbb{R}^{N \times n}, X_{flowChange} \in \mathbb{R}^{N \times n};$
n historical time steps speed attributes: $X_{speed} \in \mathbb{R}^{N \times n}, X_{TTI} \in \mathbb{R}^{N \times n};$
adjacency matrix of road network nodes: $A \in \mathbb{R}^{N \times N};$

Output:

$T + 1$ future time steps prediction traffic data: $X \in \mathbb{R}^{N \times (T+1)};$

Begin

1: initialize all parameters θ in model

2: **for each** epoch **do**:

3: get a fuzzy attribute fusion matrix X_{fuzzy} by combining $X_{time}, X_{holiday},$
 $X_{weather},$

and $X_{flowChange}$ together;

4: get X_{Effect} by calculating X_{fuzzy} using the fuzzy inference mechanism;

5: get a traffic awareness related matrix $X_{cognition}$ by combining X_{speed} and X_{TTI}
together;

6: capture spatio-temporal properties using GCN and GRU fusion mechanism with
 $X_{Effect}, X_{cognition},$ and A ;

7: calculate loss with target value and X' to update θ ;

8: **end for**

9: input test set X_{test} into the well-trained model and get output X ;

10: **return** X .

End

4.2 可解释的模糊推理机制

模糊推理机制一般由模糊化、知识库、决策和解模糊化四个主要部分组成。为了更清楚地理解模糊推理机制中的数据流向，本节在图 4.2 中展示了模糊推理机制的网络示意图。模糊网络包含四层，分别是数据输入层、数据输出层、模糊规则层以及隶属度函数层。模糊网络的输入包括四类数据，分别是 $X_{time}, X_{holiday}, X_{weather}, X_{flowChange}$ ，这些数据在模糊推理机制中是单独处理的，之前章节中详细介绍了这些输入在实际应用中的影响作用。本研究使用的隶属度函数的数量等于实际数据的模糊划分数，这样处理简化了数据的处理过程。模糊

隶属度函数层用于模糊化输入的准确数值，并得到数据隶属于某一模糊区间的概率。常用的隶属度函数包括双 S 型隶属度函数 (Dsigmf)、广义钟形隶属度函数 (Gbellmf)、高斯型隶属度函数 (Gaussmf)、联合的高斯型隶属度函数 (Gauss2mf) 等。与一般的深度学习模型不同的是模糊推理机制中的模糊规则是基于专家经验创建的，这相比于其他特征提取方法具有相当的优势。通过检查模糊规则层中的语义规则描述就可以了解数据的处理方式，这是模糊推理机制具有可解释性的关键所在。在图 4.2 中可以看到，隶属度函数层和模糊规则层之间并不是全连接的，这是因为在实际应用过程中为了降低模型的复杂度，一般会去除模糊规则层中不重要或者冗余的规则。最后的输出层的作用是对模糊规则层中输出的模糊值进行聚合和去模糊化，并获得准确的输出数值。在本研究中模糊网络的输出为 X_{Effect} ，是所有输入在模糊规则指导下输出的对交通数据认知的影响值。

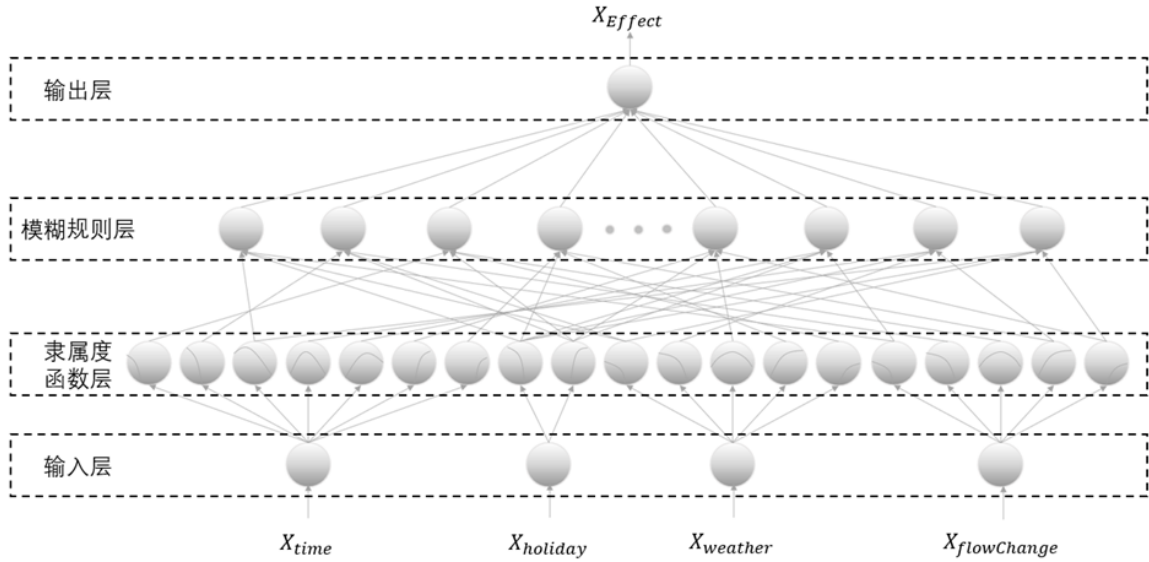


图 4.2 模糊推理过程的网络示意图

由于模糊推理机制在处理数据的过程中融合了专家经验，模型获取属性特征的能力得到了显著提高，并且有了专业知识的指导，模型的计算效率也得到了提升。更重要的是，构建的模糊规则提供了易于遵循的语义解释，提高了整个模型的透明度，为模型的决策过程提供了解释。

4.3 图卷积神经网络

由于不同道路上的交通状况相互影响，两条道路之间的距离越近，相互作用关系越大，而且这种影响是高度动态的。交通网络中的每个节点在其邻居节点和更远节点的影响下，不断改变其状态并达到最终平衡。因此，本研究引入图卷积神经网络用于道路网络节点间的空间特性捕获，该网络是交通认知领域几乎所有研究人员首选的。

为了便于后续计算工作的进行，本研究将实际路网中交通流量较大的道路抽

象为节点。根据道路之间的连通性绘制有向图，并从有向图中得到对应的邻接矩阵和度矩阵，如图 4.3 所示。图卷积神经网络中第 $l+1$ 层的计算推导如下：

$$L_{sym} = D^{-\frac{1}{2}}(D - A)D^{-\frac{1}{2}} \quad (4.1)$$

$$C_{l+1} = \sigma(L_{sym}C_lW_l) \quad (4.2)$$

$$C_0 = X, X \in \mathbb{R}^{N \times P} \quad (4.3)$$

公式 4.1 是对称归一化拉普拉斯算子 L_{sym} 的公式，其中 D 是度矩阵， A 为邻接矩阵。对称归一化拉普拉斯算子引入度矩阵解决节点自传递的问题，引入邻接矩阵解决相邻节点影响较大的问题。公式 4.2 中的使用的激活函数为非线性激活函数 $ReLU$ ， C_l 是网络中第 l 层的输出，第 l 层神经元连接的权重矩阵用 W_l 表示。公式 4.3 中的 X 是第一层的输入，是一个 $N \times P$ 的矩阵，其中 N 是节点数， P 是每个节点的特征张量维数，这里的特征张量包括属性影响特征矩阵张量和交通认知特征矩阵张量。

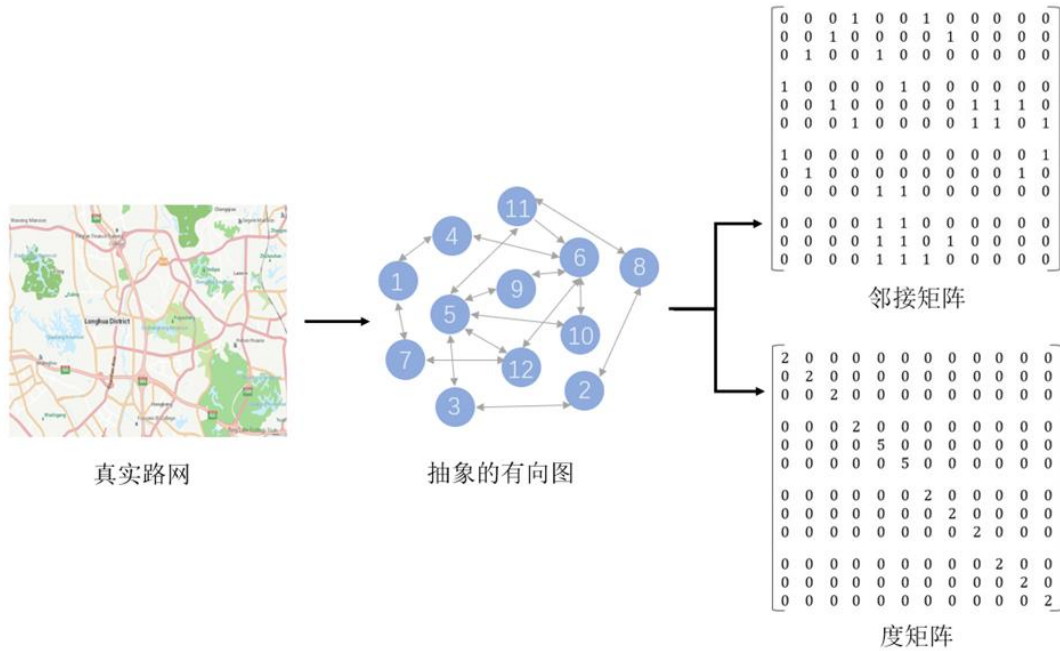


图 4.3 基于真实路网情况构建邻接矩阵以及度矩阵

4.4 门控循环网络

由于当前时刻的交通数据会收到前一时刻交通数据的影响，并且两个时间的间隔越近，影响作用越大，因此，本研究获取交通认知数据的时间特征是通过门控循环单元实现的。通过门控循环单元可以操控特征信息的积累速度，包括选择性的添加新信息以及选择性的重置累积的信息。门控循环单元相比于长短时记忆单元的优势在于其结构更简单但是性能与长短时记忆单元相当。图 4.4 提供了时间特征捕获期间，数据流向以及数据处理的清晰视图。




图 4.4 门控循环单元基本结构

门控循环单元与传统的递归神经网络相比，增加了重置门和更新门。重置门用于控制网络重置信息的时间，而更新门则控制网络添加新信息的时间。重置门和更新门的输入一样，都是当前时刻的属性特征以及前一时刻的隐藏状态，重置门和更新门在当前时刻存储的数据用公式表示如下：

$$R^t = \sigma(X^t W_{xr} + H^{t-1} W_{hr} + b_r) \quad (4.4)$$

$$Z^t = \sigma(X^t W_{xz} + H^{t-1} W_{hz} + b_z) \quad (4.5)$$

其中 $R^t \in \mathbb{R}^{N \times h}$ 表示时刻 t 存储在重置门中的信息是编码器的隐藏状态， $Z^t \in \mathbb{R}^{N \times h}$ 表示 t 存储在更新门中的数据。门控循环网络中隐藏单元的个数在公式中用 h 表示，前一时刻的隐藏状态用 H^{t-1} 表示， t 时刻的输入数据用 X^t 表示， $W_{xr} \in \mathbb{R}^{P \times h}$ ， $W_{hr} \in \mathbb{R}^{P \times h}$ ， $W_{xz} \in \mathbb{R}^{h \times h}$ ， $W_{hz} \in \mathbb{R}^{h \times h}$ 是权重矩阵， b_r ， b_z 为偏置矩阵。激活函数选用的 *sigmoid* 函数，其数据范围为 $[0,1]$ 。候选隐藏状态在时刻 t 处的计算公式如下：

$$\tilde{H}^t = \tanh(X^t W_{xh} + (R^t \odot H^{t-1}) W_{hh} + b_h) \quad (4.6)$$

与上述公式类似的 W_{xh} ， W_{hh} 为权重矩阵， b_h 为偏置矩阵。候选隐藏状态计算时使用的激活函数为 *tanh* 函数。从计算公式 4.6 中观察可得，前一时刻的隐藏状态可能会对当前时刻的候选隐藏状态造成影响，并且重置门充当了这一影响的控制开关。前面历史时刻累积下来的特征信息也会对当前时刻的隐藏状态造成影响，历史信息的管理变得十分重要，而重置门可实现这一管理操作。 $H^t \in \mathbb{R}^{N \times h}$ 表示 t 时刻的隐藏状态，要得到当前时刻的隐藏状态值，需要有当前时刻的候选隐藏状态和更新门数据，以及前一时刻的隐藏状态，起计算过程表示如下：

$$H^t = Z^t \odot H^{t-1} + (1 - Z^t) \odot \tilde{H}^t \quad (4.7)$$

门控循环单元很好的解决了一般循环神经网络 (RNN) 中常出现的梯度衰减问题, 并且对于数据时间步相隔较远的特征捕获也很有效, 其根本在于门控循环单元中的更新门的引入, 找到了合理的更新候选隐藏状态的方法。

4.5 交通认知实验过程

在本节中, 将介绍实验平台构建, 实验数据集, 比较分析以及认知性能验证等。在第一小节中, 本文详细介绍了实验中使用的两个真实数据集, 分别是深圳北站数据集 (SZBZ) 以及 Los-loop 数据集。第二小节介绍了实验中使用的五个交通认知评价指标。第三小节主要介绍根据真实数据集和评估指标调整模型中的有关参数, 这一小节又进一步分为模糊推理机制中的参数调优和深度神经网络中的参数调优。消融实验在第四小节中介绍。第五小节包含本方法与其他现有方法之间的对比实验。最后一小节中将得到的交通认知结果进行了可视化和分析。

本研究的交通认知深度学习模型是使用 Python3.7.11 编程平台和 TensorFlow2.5.0 库实现的。MATLAB R2021b 用于模糊推理机制的构建。该实验运行在第 12 代英特尔酷睿 (TM) i9-12900K 平台上, 配备 3.19GHz、64GB 内存和 NVIDIA GeForce RTX3090。

4.5.1 实验数据集

为了证明本文提出模型在实际数据中的应用性能, 本文在公开数据集上评估了提出的方法: Los-loop 速度数据集和深圳北站出租车数据集 (SZBZ)。SZBZ 数据集采集自深圳的大型交通枢纽附近, 其周边的交通运行状况直接决定了出租车到达深圳北站的效率。Los-loop 数据集时通过美国洛杉矶高速公路上的环路探测器实时收集的。在不损失一般性的情况, 本研究在实验过程中使用交通速度作为交通认知数据。下面是本研究使用的数据集的详细介绍说明。

SZBZ 数据集是 2019 年 12 月 1 日至 2019 年 12 月 31 日的在线车辆出行数据, 选择深圳北站周边地区的 12 条主要道路进行研究, 实验数据中包含七个重要属性矩阵: 第一个 12 条主要道路的邻接矩阵, 有的节点之间单向连接, 有的节点之间双向连接, 矩阵大小为 12×12 ; 第二个是交通速度矩阵, 两个相邻数据之间的时间间隔为 10 分钟, 矩阵大小为 4464×12 ; 第三个是交通拥堵指数数据则很难, 该矩阵是利用交通速度矩阵计算得到的, 矩阵大小为 12×4464 ; 第四个是时间段矩阵, 一天 24 小时根据区域内的实际流量峰值分成了几个时间段, 不同的时间段用不同的整数进行表示, 方便后续在模糊推理机制中的进一步处理, 矩阵大小为 4464×12 ; 第五个是假期矩阵, 矩阵中的 1 表示节假日, 0 表示工作日, 矩阵大小为 4464×12 ; 第六个是天气矩阵, 矩阵中不同的数字代表不同的天气状况, 相

邻天气数据之间的时间间隔为 10 分钟，矩阵大小为 4464×12 ；第七个是车流量矩阵，该矩阵中的数据是利用流出车辆数减去流入车辆数得到的，矩阵大小为 4464×12 。Los-loop 数据集由洛杉矶高速公路上的 2017 个环路探测器实时收集得到的，本研究使用的数据是 2012 年 3 月 1 日至 2012 年 3 月 7 日期间每隔 5 分钟采集得到的，与 SZBZ 数据集类似，Los-loop 数据集包括邻接矩阵、速度矩阵、时间段矩阵、假期矩阵和天气矩阵。

梯度爆炸问题是实验过程中经常会遇到的，基于此本研究在实验前归一化了实验的输入数据。训练数据集为全部数据的 80%，测试数据集为剩余的 20%。由于 SZBZ 数据集比 Los-loop 数据集更丰富，本研究使用 SZBZ 数据集进行超参数调整、输入敏感性验证实验以及与其他模型的比较实验，Los-loop 数据集则用于不同时间步长的预测实验。

4.5.2 交通认知评价指标

为了评估模型的认知性能，本文选择了 5 个评估指标来评估预测数据与真实数据之间的差异分别是决定系数（ R^2 ，Coefficient of Determination）、均方根误差（RMSE，Rooted Mean Square Error）、平均绝对误差（MAE，Mean Absolute Error）、准确性（Accuracy）、解释方差分数（var，Explained Variance Score）。时间步 t 时的 RMSE 计算方法如下：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_{pred}^t[i] - Y_{true}^t[i])^2} \quad (4.8)$$

MAE 的计算方法如下：

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_{pred}^t[i] - Y_{true}^t[i]| \quad (4.9)$$

Accuracy 的计算方法如下：

$$Accuracy = 1 - \frac{\|Y_{pred}^t[i] - Y_{true}^t[i]\|_F}{\|Y_{pred}^t[i]\|_F} \quad (4.10)$$

R^2 的计算方法如下：

$$R^2 = 1 - \frac{\sum_{i=1}^n (Y_{pred}^t[i] - Y_{true}^t[i])^2}{\sum_{i=1}^n (Y_{pred}^t[i] - \overline{Y_{pred}^t})^2} \quad (4.11)$$

var 的计算方法如下：

$$var = 1 - \frac{Var\{Y_{pred} - \widehat{Y_{true}}\}}{Var\{Y_{pred}\}} \quad (4.12)$$

其中， n 为预测的输出数据总数， Y_{pred}^t 和 Y_{true}^t 分别为时刻 t 的预测结果和真实标签。

4.5.3 模型参数设置和调整

通常，模型需要设置和调整的参数包含两部分，一部分是超参数，另一部分是模型的其余参数。按照超参数的作用不同，本文将超参数分成了两类，第一类是模糊推理机制的超参数，第二类是深度神经网络的超参数。模型的其余参数是通过使用 Adam 优化器进行调整而得到的。

(1) 模糊推理机制的超参数设置

模糊推理机制中的模糊划分、模糊隶属度函数以及模糊规则的设置是必需的。调整输入输出数据的模糊划分可以使得每个模糊分析内的数据在某些方面的性质高度相似。合适地模糊隶属度函数可以很好地描述模糊对象。模糊规则作为模糊推理机制的核心，通常基于专家经验构建。

根据深圳北站早、中、晚高峰时段，将 24 小时划分到 7 个模糊区间中，分别是 0:00-7:00、7:00-9:00、9:00-11:00、11:00-13:00、13:00-17:00、17:00-20:00、20:00-24:00，在模糊规则中分别用 0、7、9、11、13、17、20 表示，这样每个时间段内的交通流变化趋势相似。由于使用的两个数据集均是在非特殊节日采集的，本研究将日期简单的划分到两个模糊区间，分别是假期和工作日，在模糊规则中分别用 0 和 1 表示。道路上的车流量变化数被划分到九个模糊区间，分别是 [-45,-35]，[-35,-25]，[-25,-15]，[-15,-5]，[-5,5]，[5,15]，[15,25]，[25,35]，[35,45]，在模糊规则中分别用 -4、-3、-2、-1、0、1、2、3、4 表示，其中负数表示该车道车流量减少，整数表示该车道车流量增加。天气数据则划分了晴天、多云、有雾、小雨、中雨、大雨 6 个模糊区间，在模糊规则中分别使用 1, 2, 3, 4, 5, 6 表示。模糊推理机制的输出值表示外部属性对交通速度预测的影响，本研究根据对交通速度预测的影响程度不同，分成小、中、大、超大 4 个模糊区间，在模糊规则中分别使用 1, 2, 3, 4 表示。

在比较了广义钟形隶属度函数(Gbellmf)、联合高斯型隶属度函数(Gauss2MF)、双 S 型隶属度函数(Dsigmf)、高斯隶属度函数(Guassmf)等几种经典的模糊隶属度函数后，发现 Guassmf 更适合本研究的应用场景。高斯隶属度函数的中心设置为模糊区间的中心。本研究常识将高斯隶属度函数的宽度设置成 0.1、0.2、0.3，对比实验结果发现宽度设置成 0.2 效果最佳。

模糊规则是根据专家经验和数据的实际应用场景进行设置的。通常，模糊规则可以表示为语义结构为“IF-THEN”的句子。在这种情况下，输入模糊数据包括 4 部分，包括时间段、节假日、天气以及交通流量变化。输出的准确值表示上述外部属性对交通认知的影响。在本文进行实验的过程中，发现构建了 56 条模糊规则的情况下产生了最佳的实验结果，下面是其中一些比较重要的规则：

IF flowChange is zero AND time is seven THEN effect is small

IF flowChange is three AND time is seven THEN effect is large

IF holiday is zero AND time is nine THEN effect is super large (4.13)

IF weather is foggy THEN effect is middle

随着模糊规则的不断完善，在表面观测窗口可以获取经过模糊决策推理矩阵运算和去模糊化后的三维坐标图，展示如图 4.5。由于维度的限制，三维坐标图只能显示其中两个输入对交通认知的影响。图中 x 轴和 y 轴分别表示输入模糊变化假期和流量变化，z 轴表示输出的影响值，坐标范围是模糊变量的域。从图中观察可知，三维坐标图相当于模糊影响查找表，可以直观地验证模糊规则的建立是否合理。当控制期望不在模糊推理输出结论的中心附近时，需要重新调整隶属度函数和模糊规则，直到满足需求为止。




图 4.5 模糊规则的 3D 可视化

(2) 深度神经网络的超参数设置

深度神经网络需要设置的超参数包括训练周期数、学习率、GRU 隐藏单元数、训练批量大小以及输入数据的时间长度。从图 4.6 中可以观察得到，当训练周期达到 3000 次以后，均方根误差曲线逐渐趋平，这表明，在此之后模型性能基本稳定。为了节省训练时间，本研究将后续实验的训练次数均设置为 3000，并根据经验将学习率设置为 0.001。下面我们还通过实验比较了不同实验设置下的其他三个参数的影响。如图 4.7 所示，本研究对 GRU 隐藏单元数分别为 8、16、32、64 和 128 进行了实验，使用上述 5 个评估指标进行比较发现，GRU 隐藏单元个数设置为 64 效果更好。本研究进行了批量的大小分别为 8、16、32、64、128 的对比实验，实验结果如图 4.8 的所示，观察可得数据批量大小设置为 32 效果最佳。与之前类似的，本文对时间步长为 10、12、14、16 的模型分别进行了实验，实验结果如图 4.9 所示，观察可得时间步长设置为 12 的模型具有最佳的认知性能。




图 4.6 均方根误差在训练周期增加时的变化




图 4.7 调整 GRU 隐藏单元数量的对比实验




图 4.8 调整训练数据批量大小的对比实验




图 4.9 调整历史数据时间步长的对比实验

(3) 模型其余参数的调整

模型的其余参数主要包括深度神经网络各层节点的权重和偏差，本研究使用 Adam 优化器进行调整。优化过程如下，首先利用具有从过去训练中得到知识的训练样本生成新的梯度，然后基于获得的梯度计算偏置第一矩估计值和偏置第二弯矩估计值，并最终用于校正偏差和更新模型参数。

4.5.4 交通认知模型输入敏感性验证实验

为了更好地验证外部属性对交通认知的影响，本研究设置了四组输入敏感性验证实验，实验结果见表 4.1。表中的输入数据列为了表示方便，使用了一些缩写，其中 H 表示节假日数据，W 表示天气数据，T 表示时间段数据，F 表示交通流量变化数据。第一组实验仅在模型中输入历史速度数据和路网邻接矩阵，第二组实验在第一组的基础上加入了天气数据和假期数据，第三组实验在第二组的基础上加入了时间段数据和车流量变化数据，第四组实验也就是本文提出的方法，在第三组实验的基础上加入了交通拥堵指数数据。

表 4.1 输入敏感性验证实验结果对比

输入数据	RMSE	MAE	Accuracy	R^2	Var
Only speed	6.4070	4.5751	0.8592	0.7634	0.7634
H&W	6.1835	4.2981	0.8640	0.7791	0.7791
H&W&T	3.4683	2.5029	0.9237	0.9305	0.9325
本文方法	3.3567	2.3982	0.9262	0.9349	0.9363

观察表 4.1 中的实验结果发现，输入仅包含历史速度和邻接矩阵的实验具有最差的预测性能，随着其他属性的添加，预测的性能越来越好。在外部属性数据逐渐加入的过程中，第二组和第三组实验的性能差异最大，表明周期数据和流量变化数据对预测性能的影响较大。本研究最终使用的方法相比于第一组实验的预测准确率提高了 22.65%，由此可以判断本研究所选的外部属性对交通认知的性能提升有显著贡献。

4.5.5 对比实验分析

本研究将对比实验进一步分成了模型间对比实验和模型内对比实验。其中模型间对比实验是将本文提出的模型与其他交通速度预测模型进行对比；模型内对比实验是比较模型在不同预测周期下的预测性能，下面将详细介绍这两组实验。

模型间的对比实验，本研究选择了五个具有代表性的模型与本模型进行比较，这五个模型分别是：

1) 历史平均模型（HA）^[132]：该模型使用历史交通速度的平均值作为未来交通速度的预测值。

2) 自回归积分移动平均模型（ARIMA）^[133]：该模型将观察到的时间服务器数据拟合到参数模型中，以预测未来的交通速度。

3) 支持向量回归模型（SVR）^[134]：该模型使用历史交通速度来训练模型并获取输入输出之间的关系，将未来的交通速度数据输入模型以预测未来的交通速度，本文使用线性核，惩罚项为 0.001。

4) 时间图卷积网络模型（T-GCN）^[135]：该模型融合了门控循环单元 GRU 以及图卷积神经网络 GCN，用于捕获交通速度数据中的时空属性。

5) 属性增强时空图卷积神经网络模型（AST-GCN）^[136]：该模型使用卷积神经网络和门控循环单元来捕获速度数据和一些外部属性数据中的时空特性，并对未来交通速度进行预测。

上述模型的所有代码都是开源的。为了比较这些模型在不同预测时长下的预测性能，本研究分别对 10 分钟、30 分钟、60 分钟下不同模型的预测性能进行了比较。所有模型的超参数设置都相同，实验使用的数据集是深圳北站网约车数据集。实验结果见表 4.2。对比实验结果发现，10 分钟的预测时间下，本模型与 SVR、T-GCN 以及 AST-GCN 的预测性能大致相同，SVR 的性能稍好一些。在 30 分钟和 60 分钟的预测时间下，本模型的预测精度比其他模型的高 0.61%-32.03%。另外，随着预测时间变长，其他模型的预测性能明显下降，但本模型在 60 分钟预测时长下也保持了 90% 以上的预测准确率，比其他模型高 0.61%-29.15%。

表 4.2 不同模型的预测性能对比

预测 时长	评估指标	HA	ARIMA	SVR	T-GCN	AST-GCN	Ours
10 分 钟	RMSE	12.1017	13.6281	2.8189	3.3582	3.4837	3.3656
	MAE	9.7023	9.9588	1.7611	2.3567	2.4944	2.3886
	Accuracy	0.7338	0.6995	0.9380	0.9261	0.9233	0.9259
	R^2	0.1538	*	0.9541	0.9348	0.9299	0.9346
	Var	0.1538	*	0.9541	0.9352	0.9324	0.9347
30 分 钟	RMSE	12.1017	13.6245	8.7012	4.2170	6.1624	3.3567
	MAE	9.7023	9.9578	6.3561	3.0831	4.4420	2.3982
	Accuracy	0.7338	0.7015	0.8086	0.9071	0.8645	0.9262
	R^2	0.1538	*	0.5626	0.8973	0.7811	0.9349
	Var	0.1538	*	0.5626	0.9004	0.7811	0.9363
60 分 钟	RMSE	12.1017	13.6151	10.7464	4.4827	6.6277	4.2312
	MAE	9.7023	9.9492	8.5586	3.2744	4.7561	3.1099
	Accuracy	0.7338	0.7023	0.7638	0.9015	0.8542	0.9070
	R^2	0.1538	*	0.3343	0.8842	0.7462	0.8968
	Var	0.1538	*	0.3343	0.8843	0.7484	0.8973

为了对比不同预测二时长下本模型的预测精度，本研究利用 Los-loop 数据集进行了实验，验证了本模型在更精细的预测时长下的预测性能。模型的预测时长分别设置为 10、20、30、40、50 和 60 分钟，预测结果如表 4.3。

表 4.3 不同预测时长下的性能比较

评估指标	10 分钟	20 分钟	30 分钟	40 分钟	50 分钟	60 分钟
RMSE	4.8408	5.5554	6.1603	6.6566	7.1217	7.3882
MAE	3.0703	3.4820	3.8280	4.0499	4.3539	4.4996
Accuracy	0.9176	0.9054	0.8951	0.8866	0.8787	0.8741
R^2	0.8784	0.8402	0.8039	0.7716	0.7391	0.7197
Var	0.8784	0.8403	0.8040	0.7725	0.7394	0.7208

从实验结果可以看出，当预测时长为 10 分钟时，本模型具有最佳的预测性能。当预测时间变长时，模型的预测性能逐渐下降，这是符合常理的。但是，本模型在设定的预测时长下的预测准确率均达到了 87% 以上，60 分钟预测时长下的预测

准确率仅比 10 分钟预测时长下的准确率低 4.98%。由此可以判断，本模型不仅能预测短时长下的交通速度，还能为长时间的预测提供有价值的参考。

4.5.6 认知结果可视化

在本章的最后，我们分别使用所有数据和其中某一天的数据来可视化预测结果和真实值，目的是更直观地感受预测值和真实值之间的相似性，这也便于找到本模型的缺点并加以改善。图 4.10、图 4.11、图 4.12 分别展示了预测时长为 10 分钟、30 分钟和 60 分钟下的预测结果的可视化曲线。另外，本小节还提供了表 4.4 用于比较一天数据和所有数据在不同预测时长下的性能，以更好地分析可视化结果。




图 4.10 预测时长为 10 分钟的数据可视化

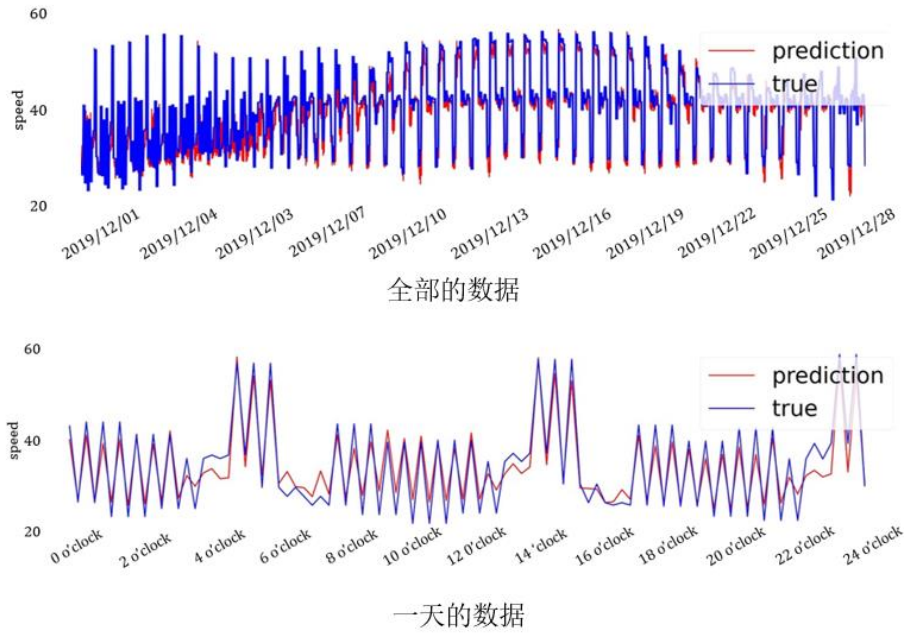


图 4.11 预测时长为 30 分钟的数据可视化




图 4.12 预测时长为 60 分钟的数据可视化

通过比较不同预测时长下的可视化结果，不难发现本模型在速度的周期峰值处具有良好地预测精度。从可视化图像中还可以看出，当两个速度峰值相距较远时，两个峰值之间的预测性能相对较差，这体现在预测值曲线和真实值曲线之间的重叠度减少上，本研究查阅有关资料发现可能时模型中门控循环单元的使用，可能会导致当前时刻的预测结果与上一时刻的预测结果相关，一旦前后速度差异显著，就会导致模型的预测性能下降。尽管预测时长过长时，预测值曲线与真实值曲线的重叠度下降，但是在 60 分钟的预测时长下，预测准确率仍高于 90%，

这与表 4.4 中的性能对比结果一致。总体来看，模型预测的速度变化趋势与实际速度的变化趋势一致，认知表现比较突出。

表 4.4 一天的数据与全部数据的预测性能比较

数据量	10 分钟		30 分钟		60 分钟	
	RMSE	Accuracy	RMSE	Accuracy	RMSE	Accuracy
一天的数据	3.4735	0.9235	3.4032	0.9251	4.6573	0.8976
全部的数据	3.3656	0.9259	3.3567	0.9262	4.2312	0.9070

4.6 本章小结

本章具体介绍了基于模糊理论的智能交通认知深度学习模型。在介绍了模型的总体结构后，分别介绍了模型中的不同子模块的内部实现细节以及作用原理，包括可解释的模糊推理机制、用于提取空间特性的图卷积神经网络、用于提取时间特性的门控循环网络。最后对本文提出的模型进行了对比实验分析，实验类型包括消融实验、本模型与其他模型的对比实验、以及模型本身的对比实验，为了进一步分析预测结果并得出结论，本章还提供了结果的可视化。考虑到实验结果真实性，本文使用两个的数据集均为公开数据集。

第5章 智能交通认知应用的模糊机制与可解释方法

基于前面的工作，本章实现了基于模糊理论的交通认知应用可解释算法，本研究所指的交通认知应用即外部属性影响分析。外部属性影响的分析能够提高交通认知的准确性，为智能交通系统提供决策帮助，通过降低交通拥堵情况发生的概率进一步提高智能交通系统的运行效率。传统的交通认知模型更关注交通数据本身的特性，比如交通流量、交通速度等，但是在不同的交通场景中，交通认知会受到不同外部属性的影响，并且外部属性之间的相互作用关系也是不容忽视的。因此利用模糊理论的特点，即更有效且可解释的方法是在特征提取和决策推断过程中加入专家经验的指导而不是直接用深度学习模型提取属性影响关系。基于这一想法，本研究利用模糊理论的特征提取特点，并结合决定系数对交通认知特性的描述，在前述模型输出的交通认知结果的基础上，完成了外部属性影响特征的描述，并进行了更加有效的外部属性影响分析。

5.1 交通认知应用可解释算法

在前面的交通认知工作中，本研究利用模糊理论为智能交通认知提供了可解释的推理过程。在本章智能交通认知应用中，同样需要用到模糊理论对外部属性影响进行可解释的分析。以本实验输出的交通认知结果为例，已知交通认知结果是一组预测得到的速度矩阵 $X'_{speed} \in \mathbb{R}^{\tau \times N}$ 由 τ 个时间步的交通速度组成：

$$X'_{speed} = [S_1, S_2, \dots, S_\tau] \quad (5.1)$$

其中 S_i 为第 i 个时间步的交通速度，表示为：

$$S_i = [s_i^1, s_i^2, \dots, s_i^N] \quad (5.2)$$

由交通场景中的 N 条道路在 i 时刻捕获到的速度数据组成。考虑到交通速度预测的准确性会受到输入的外部属性种类的直接影响，本研究建立了外部属性与预测的交通速度之间的联系，即通过速度预测的准确性间接地反映外部属性的影响。本研究采用的评估预测准确性的指标是决定系数 R^2 ，其定义如下：

$$R^2 = 1 - \frac{\sum_{i=1}^N \sum_{j=1}^{\tau} (X'_{speed}[i][j] - X_{speed}[i][j])^2}{\sum_{i=1}^N \sum_{j=1}^{\tau} (X'_{speed}[i][j] - \overline{X'_{speed}})^2} \quad (5.3)$$

其中 $X'_{speed}[i][j]$ 表示预测的第 i 条道路在 j 时刻的速度数据， $X_{speed}[i][j]$ 表示第 i 条道路在 j 时刻的真实速度数据。 $\overline{X'_{speed}}$ 表示预测速度的平均值。

决定系数 R^2 的值介于 0 到 1 之间，该值越接近于 1，表示模型回归拟合的效果越好，在本应用中即模型的预测性能越好。因此在不知道模型决策过程的情况下，

通过控制外部属性的输入以及观察决定系数的变化，就能得到外部属性对交通认知的影响。在这个过程中，合理的模糊规则发挥着很大的作用，也是交通认知应用算法可解释的关键所在。本研究将外部属性对交通认知的影响分成了三大类，包括影响较小、影响中等、影响较大三大类，在模糊规则中分别用 small、middle、large 表示。基于启发式地确定了模糊分类的阈值参数 λ_1 和 λ_2 。智能交通认知应用的模糊规则列举如下：

IF the change in R^2 is greater than 0 and less than λ_1 THEN effect is small
IF the change in R^2 is greater than λ_1 and less than λ_2 THEN effect is middle (5.4)
IF the change in R^2 is greater than λ_2 and less than 1 THEN effect is large

当决定系数的变化率小于 λ_1 时，外部属性对交通认知的影响较小；当决定系数的变化率大于 λ_1 且小于 λ_2 时，外部属性对交通认知的影响中等；当决定系数的变化率大于 λ_2 时，外部属性对交通认知的影响较大。

5.2 交通认知应用隶属度函数

交通认知应用隶属度函数用于描述外部属性影响属于某一模糊区间的可能性。本研究使用的交通认知应用隶属度函数为模糊高斯隶属度函数，其定义如下：

$$\mu(x) = e^{-k(x-\alpha)^2} \quad (5.5)$$

其中 x 为高斯隶属度函数的输入，即决定系数 R^2 的变化值， k 为隶属度函数的宽度， α 为隶属度函数的中心位置。

在上一节中已经介绍了本应用使用了三个模糊集，这三个模糊集的统一形式为：

$$A_i = \{(x, \mu_i(x)) | \mu_i(x) = e^{-k(x-\alpha_i)^2}, i \in \{1, 2, 3\}\} \quad (5.6)$$

A_i 用来表示第 i 个模糊集， x 表示隶属度函数的输入值， μ_i 表示第 i 个隶属度函数，三个隶属度函数的宽度一致，均用 k 表示， $k > 0$ ， α_i 表示第 i 个隶属度函数的中心。本研究使用的三个模糊集的隶属度函数具体定义为：

$$\begin{aligned} \mu_1(x) &= e^{-k(x-\alpha_1)^2} \\ \mu_2(x) &= e^{-k(x-\alpha_2)^2} \\ \mu_3(x) &= e^{-k(x-\alpha_3)^2} \end{aligned} \quad (5.7)$$

其中 α_1 ， α_2 ， α_3 ， k 的具体数值将在 5.3.3 章节中介绍。

5.3 交通认知应用实验分析

本节首先介绍用于评估外部属性影响的指标——增长率（Growth Rate, GR）^[136]。接下来是对外部属性影响算法的概述，以及用于测试本应用方法的真实交通数据集和实验部署工作的介绍。最后使用增长率来分析本研究方法应用于仿真

环境以及真实交通数据集时的结果。

5.3.1 属性影响评价指标

增长率被本研究方法来衡量外部属性对交通认知的影响。例如，没有外部属性输入的情况下模型进行交通认知的决定系数为 0.7634，当输入某一种外部属性后，模型进行交通认知的决定系数为 0.7791，那么增长率 $GR=0.0206$ 。增长率越高，表明该外部属性对交通认知的影响越大。 GR 的定义如下：

$$GR_{effect} = \frac{R_{attribute}^2 - R_{only}^2}{R_{only}^2} \quad (5.8)$$

其中， $R_{attribute}^2$ 为加入某种属性后本方法进行交通认知得到的决定系数， R_{only}^2 为没有外部属性输入，即模型输入只有交通数据时，进行交通认知得到的决定系数。

根据上述例子可知，增长率 GR 的值较小，不便于后续的模糊分类工作，因此本研究将增长率进行归一化，使增长率的数值分布更均匀，且数值大小位于 0 到 1 之间。增长率的归一化公式定义如下：

$$GR_{normalize} = \frac{GR_{original} - GR_{min}}{GR_{max} - GR_{min}} \quad (5.9)$$

其中 $GR_{original}$ 是原始的增长率， GR_{min} 是增长率中的最小值， GR_{max} 是增长率中的最大值。

5.3.2 数据集和实验部署

（1）数据集

本章的智能交通认知应用为第四章智能交通认知任务的后续工作，因此本章实验部分的相关数据集仍然使用智能交通认知深度学习模型实验部分的数据集。即深圳北站的出租车数据集（SZBZ），该数据集的详细介绍见 4.5.1 章节。

（2）实验部署

本实验的目的是获得外部属性影响的更细致的信息，即不同外部属性，以及不同外部属性组合输入模型后，对模型进行交通认知的影响。因此，本研究对此进行了两类实验，第一类是输入单个的外部属性数据，第二类是输入不同外部属性组合后的数据。每个实验进行交通认知后得到的决定系数都与模型输入只有交通数据的决定系数进行比较，这样得到的不同的模型交通认知增长率，相互之间也具有可比性。

此外，为了让交通认知应用的处理过程更直观，本文还将不同外部属性输入情况下的决定系数的增长率计算过程用算法 2 进行了表示。

算法2 决定系数增长率的计算

算法2 决定系数增长率的计算

Input: Feature tensor: $\mathcal{F} \in \mathbb{R}^{T \times \max_N \times C}$

Adjacency tensor: $\mathcal{A} \in \mathbb{R}^{T \times \max_N \times \max_N}$

Input:

one of the four attributes, which all have n historical time steps: $X_{time} \in \mathbb{R}^{N \times n}$,
 $X_{holiday} \in \mathbb{R}^{N \times n}$, $X_{weather} \in \mathbb{R}^{N \times n}$, $X_{flowChange} \in \mathbb{R}^{N \times n}$; or none;
n historical time steps speed attributes: $X_{speed} \in \mathbb{R}^{N \times n}$, $X_{TTI} \in \mathbb{R}^{N \times n}$;
adjacency matrix of road network nodes: $A \in \mathbb{R}^{N \times N}$;

Output:

The growth rate of the coefficient of determination: GR ;

Begin

1: initialize all parameters θ in model

2: **for each epoch do:**

3: get a fuzzy attribute fusion matrix X_{fuzzy} by setting the combination of X_{time} ,
 $X_{holiday}$, $X_{weather}$, and $X_{flowChange}$, or not entering;

4: when the X_{fuzzy} is not null, get X_{Effect} by calculating X_{fuzzy} using the fuzzy
inference mechanism; else set X_{Effect} to null;

5: get a traffic awareness related matrix $X_{cognition}$ by combining X_{speed} and X_{TTI}
together;

6: capture spatio-temporal properties using GCN and GRU fusion mechanism with
 X_{Effect} , $X_{cognition}$, and A ;

7: calculate the loss using the target value and X' to update θ ;

8: **end for**

9: input the test set X_{test} into the training-ready model to obtain the traffic
cognition matrix X ;

10: calculate R^2 with real data and X ;

11: get R_1^2 without external attribute input;

12: get R_i^2 when the input is a combination of external attributes;

13: calculate GR with R_1^2 and R_i^2 ;

14: **return** GR .

End

5.3.3 实验分析

在表 5.1 中,报告了本研究方法在不同外部属性组合输入情况下,决定系数、
决定系数增长率、决定系数增长率的归一化值。外部属性的组合可以是输入某一

种外部属性也可以是由不同外部属性组合后作为输入。不同的外部属性输入对应着不同的真实交通场景，进而会造成不同的交通认知影响。

表 5.1 不同外部属性输入下的 R^2 、GR、GR 的归一化值

外部属性输入	外部属性影响		
	R^2	GR	GR 的归一化值
None	0.7634	*	*0.221
Time	0.8165	0.0698	0.2991
Weather	0.7662	0.0037	0
Holiday	0.7723	0.0117	0.0362
Flow change	0.7705	0.0093	0.0253
H&W	0.7791	0.0206	0.0765
H&W&T	0.9305	0.2189	0.9738
H&W&T&F	0.9349	0.2247	1

从表 5.1 中可以观察到，时间段信息对交通认知的影响最大，这是因为人们的出行规律与日常生活作息有很大的相关性，从此也可以推断出，在具有不同生活作息的城市里，交通认知会受到时间段信息不同程度的影响。对交通认知影响最小的是天气信息，这是因为天气没有明显的变化周期，并且由于数据集中的天数跨越往往不会太长，而短时间内天气往往不会有太大的变化。另外，可以看出不同外部属性的组合输入会对交通认知产生不同程度的积极影响。

基于上表中的实验数据，本文绘制了外部属性影响隶属度函数曲线，如图 5.1 所示。




图 5.1 外部属性影响隶属度函数曲线

图中三个隶属度函数的中心位置分别为-0.1，0.5，1.1，隶属度函数的宽度均为 0.8。另外阈值参数 λ_1 和 λ_2 的值分别为 0.2 和 0.8。当 GR 的归一化值小于 λ_1 时，

表示该外部属性输入对交通认知的影响较小；当 GR 的归一化值大于 λ_1 且小于 λ_2 时，表示该外部属性输入对交通认知的影响中等；当 GR 的归一化值大于 λ_2 时，表示该外部属性输入对交通认知的影响较大。

5.4 本章小结

本研究构建基于模糊理论的外部属性影响分析应用框架在本章进行了详细的介绍。对于本研究来说，模糊隶属度函数是一种很好的提取不同外部属性输入下的影响特性的方法，因此本章应用决定系数，建立了外部属性与交通认知之间的联系。相比传统的特征提取方法，本章提出的方法更注重外部属性对交通认知的作用规则，通过制定具有专家经验的属性影响规则，可以更好地提取外部属性特性，并且让这一决策过程变得可解释。另外，通过进一步对决定系数的处理以及模糊隶属度函数的应用，本章将外部属性的影响以更简单易懂的曲线形式绘制出来，更方便后续应用中对数据进行简单直观的分析。

结 论

1. 本文工作总结

随着人工智能的飞速发展,智能交通系统正逐渐从感知智能向认知智能转变。智能交通认知是为智能交通系统提供决策帮助的一类研究,旨在做出更好的出行决策,减少交通拥堵,提高交通运营效率。各类智能交通认知方法已经在智能交通领域得到了广泛的应用,随着研究的进一步深入,研究人员逐渐将研究的重心从提高模型性能转移到提高模型实际应用的安全性上,其中亟待解决的就是深度学习模型的可解释性问题。认知模型的低可解释性必然会限制模型在某些敏感领域的应用,另外,如何在不降低模型认知性能的同时提供解释也是研究人员需要重点考虑的问题。在交通场景中,道路上车辆的状态,外部因素对交通认知的影响,外部属性之间的相互影响关系都在时时刻刻发生变化,因此本文主要围绕以下几个主题进行研究,分别是如何获取交通数据中的时空特性,如何捕获外部属性对交通认知的影响,如何提高交通认知模型整体的可解释性。

对于研究面临的交通认知问题和外部属性影响分析问题,本研究从解决交通数据时空特性提取、外部属性影响特征提取、外部属性影响分析工作等角度着手,展开了以下研究工作,包括数据处理、可解释交通认知模型构建、外部属性影响分析:

(1) 数据处理过程

1) 通过图模型表达不同道路之间的相互影响作用

在交通场景中,道路上车辆的速度、流量等特征不仅在时间上存在相互影响作用,在空间上也有着相互影响的规律。因为相互连通的道路上的车辆可以相互流动,并且车流会随着时间的推移朝着特定的方向移动。联想到具有类似结构的互联网,本研究通过图模型来描述交通场景,具体来说,不同道路之间的连接情况用图模型中的有向边进行表示,图模型中的节点则用于表示交通场景中的道路。基于此方法,本研究建立了不同道路之间的连通关系,方便后续交通认知模型进一步提取交通数据的时空特性。

2) 利用模糊理论描述外部属性数据

外部属性数据多种多样,数据形式也各不相同,如何高效地将外部属性数据处理成模型方便计算的数据是本研究的一个难点所在。模糊理论包含模糊集合理论、模糊逻辑理论、模糊推理理论和模糊控制理论等,可以用于描述某个不确定的对象,对模糊概念加以概括。利用模糊理论便可以准确且高效地处理格式各异

的外部属性数据。例如，时间段数据是一类比较抽象的数据，本研究想提取某一具有相似交通状况的时间段内的特征信息，利用常用的数据处理方法将会使得工作量大大增加，然而利用模糊理论即可将具有相似交通状况的时间都划分到同一个模糊区间内，并将不同的区间用不同的整数进行表示。用同样的方法处理所有的外部属性数据，使得数据格式统一，并且处理过程相对简单。

3) 利用模糊理论分析外部属性影响

通常分析属性影响会使用某一个既定的评价指标，通过数值的大小进行比较分析。但这对于非专业人员来说理解起来比较困难，并且很难分析得到存在影响差异的根本原因。因此，本研究使用模糊隶属度函数对不同外部属性输入下得到的交通认知结果进行模糊分类。进一步的，通过多个阈值参数可以将模糊区间进行划分，得到的子模糊区间可以用自然语言进行描述，这对于非专业人员来说是易懂且直观的。

(2) 可解释交通认知模型构建

1) 构建了模糊推理机制获取外部属性的影响特征

如何利用预处理后的外部属性数据，得到外部属性对交通认知的影响是本研究需要考虑的重点问题之一。与现有的特征提取方法不同，本研究使用模糊推理机制进行外部属性影响特征提取。模糊推理机制由模糊隶属度函数、模糊规则库以及解模糊化函数组成。模糊推理机制中的模糊规则利用该领域的专家经验进行构建，可以指导模型提取特征，提高模型进行特征提取的效率，最重要的是模型的决策过程可以通过语义形式进行表达，进而提高模型整体的可解释性。另外，模糊推理机制得到的输出是精确的数值，方便本研究方法的其他模块对外部属性影响特征的进一步利用。

2) 构建了图卷积网络提取交通数据的空间特性

本研究利用图卷积神经网络捕获交通路网中各道路之间的相互影响关系，这是现有研究最常用的模型之一。对称归一化拉普拉斯算子用于描述道路节点间的信息势差，并且在计算之前需要对邻接矩阵进行对称归一化操作，拉普拉斯算子引入度矩阵解决了道路节点间自传递的问题，并且邻接矩阵归一化的操作也解决了相邻节点影响较大的问题。

3) 构建了门控循环神经网络提取交通数据的时间特性

考虑到道路上当前的车流量会受到前面时间段内车流量的影响，并且两个时刻间隔越近，其所受的影响越大，本研究构建了门控循环神经网络来捕获交通数据的时间依赖特性。门控循环神经网络在递归神经网络的基础上增加了更新门和复位门，使得门控循环单元可以有选择的添加新信息和清除以往积累的信息。门控循环单元相比于长短时记忆单元的优势在于其结构简单并且性能优越。

(3) 外部属性影响分析

外部属性对交通认知的影响是不容忽视的，虽然现有的方法有考虑外部属性对交通认知的影响，但往往考虑的不够全面，考虑不同外部属性相互影响关系的研究方法就更少了。为了更直接的观察外部属性对交通认知的影响，本研究建立了外部属性与交通认知结果之间的联系，并且利用模糊理论，将外部属性影响用可理解的方式进行了表达。该过程引入了决定系数、决定系数的增长率、决定系数增长率的归一化值等概念，通过数据转换过程，可以实现外部属性影响的实时分析。

2. 下一步研究展望

本文基于模糊理论构建了可解释的智能交通认知深度学习模型，并且进一步利用交通认知结果构建了外部属性影响分析模型。本研究提出的两个方法都关注交通场景中道路与道路之间的相互影响，并加以分析交通场景中外部属性对交通认知的影响，重点关注模型整体的可解释性以及实验数据的时空特性捕获。但由于科研时间以及个人能力的限制，本研究方法仍有很大的改进空间。

（1）在实际交通场景中，交通认知会受到天气、时间段、假期、车流量变化的影响以外，还可能会受到交通事故、人流量等其他外部因素的影响，如果可以收集到更多的外部属性数据，并有效地提取其中的影响特征，模型的交通认知性能将更加稳定和优越。

（2）本研究方法在进行模型性能验证时，为了方便构建模糊规则，只用交通速度数据进行了验证，事实上，本模型对于其他具有时空特性的数据也具有认知能力。如何能够自构建模糊规则以更好地应用于其他专业领域，是本研究方法有待进一步改进的。

（3）本研究方法在提取交通数据的时空特性方面，还可以参考最新的时空特性提取模型进行改进，并且不仅仅是交通领域的模型，还可以将其他领域的模型迁移应用到本模型中。

参考文献

- [1] K. Lin, J. Gao, Y. Li, et al. Multi-Granularity Collaborative Decision With Cognitive Networking in Intelligent Transportation Systems. *IEEE Transactions on Intelligent Transportation Systems*, 2023, 24(1): 1088-1098
- [2] Khan, M.U., Hosseinzadeh, M., Mosavi, A. An Intersection-Based Routing Scheme Using Q-Learning in Vehicular Ad Hoc Networks for Traffic Management in the Intelligent Transportation System. *Mathematics*, 2022, <https://doi.org/10.3390/math10203731>
- [3] 潘浩国.智能交通系统在建设项目交通疏解中的应用. *福建交通科技*, 2021, 188(11):107-109
- [4] C. Gong, C. Zong, C. Dai, et al. Adaptive Personalized Steer-by-Wire System Design Based on Driving Style Identification. In: *IEEE 25th International Conference on Intelligent Transportation Systems*. China: 2022, 1367-1374
- [5] Oliveira, Rui, Siddharth H. Nair, et al. Interaction and Decision Making-aware Motion Planning using Branch Model Predictive Control. *ArXiv*, 2023, abs/2302.00060
- [6] Hongbin Yin, S.C. Wong, Jianmin Xu, et al. Urban traffic flow prediction using a fuzzy-neural approach. *Transportation Research Part C-Emerging Technologies*, 2002, 10(2): 85-98
- [7] 曹洁,苏广,张红等.CapsNet融合D-BiLSTM的区域复杂路网交通速度预测. *吉林大学学报(工学版)*, 2023, 1-9
- [8] T. Zeng, J. Guo, K. Kim, et al. Multi-Task Federated Learning for Traffic Prediction and Its Application to Route Planning. In: *IEEE Intelligent Vehicles Symposium*. Japan: Nagoya, 2021, 451-457
- [9] J. Wang, W. Chai, A. Venkatachal, et al. A Survey on Driver Behavior Analysis From In-Vehicle Cameras. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(8): 10186-10209
- [10] Erfan Babaee Tirkolaee, Nadi Serhan Aydin. Integrated design of sustainable supply chain and transportation network using a fuzzy bi-level decision support system for perishable products. *Expert Systems with Applications*, 2022, 195: 116628
- [11] Y. Wang, Y. Xiao, X. Xie, et al. Real-time Traffic Pattern Analysis and

- Inference with Sparse Video Surveillance Information. International Joint Conference on Artificial Intelligence. 2018, <https://doi.org/10.24963/ijcai.2018%2F496>
- [12] 钱磊,赵长海,孙明. 关于我国智能交通系统发展的思考. 内蒙古科技与经济, 2021, 485(19):94-95+97
- [13] S. K. Rajput, J. Chandra Patni. Vehicle Identification and Classification for Smart Transportation using Artificial Intelligence- A Review. In: 2022 15th International Conference on Human System Interaction. Australia: Melbourne, 2022, 1-9
- [14] Nama, M. Kelkin, Ankita Nath, et al. Machine learning - based traffic scheduling techniques for intelligent transportation system: Opportunities and challenges. International Journal of Communication Systems, 2021, 34, <https://doi.org/10.1002/dac.4814>
- [15] Hang, P., Chen, X. Towards Autonomous Driving: Review and Perspectives on Configuration and Control of Four-Wheel Independent Drive/Steering Electric Vehicles. Actuators, 2021, 10: 184
- [16] Mahmud, Khaled, Khonika Gope, et al. Possible Causes & Solutions of Traffic Jam and Their Impact on the Economy of Dhaka City. The Journal of Men's Studies, 2012, 2: 112
- [17] Yuan, H., Li, G. A Survey of Traffic Prediction: from Spatio-Temporal Data to Intelligent Transportation. Data Science and Engineering, 2021, 6: 63–85
- [18] Krumm J, Horvitz E. Locadio: inferring motion and location from wi-fi signal strengths. In: The First Annual International Conference on Mobile and Ubiquitous Systems: Networking and Services, 2004, 4–13
- [19] Sohn T, Varshavsky A, LaMarca A, et al. (2006) Mobility detection using everyday gsm traces. Ubiquitous Computing, 2006, 212-224
- [20] Zhu Y, Zheng Y, Zhang L, et al. Inferring taxi status using gps trajectories. ArXiv, 2011, abs/1205.4378
- [21] Zheng Y, Liu L, Wang L, et al. Learning transportation mode from raw gps data for geographic applications on the web. In: The Web Conference, 2008, 247–256
- [22] Liao L, Patterson DJ, Fox D, et al. Learning and inferring transportation routines. Artif. Intell, 2004, 171(5–6):311–331
- [23] Yin J, Chai X, Yang Q. High-level goal recognition in a wireless lan. In: AAAI Conference on Artificial Intelligence, 2004, 578–584

- [24] Stenneth L, Wolfson O, Yu PS, et al. Transportation mode detection using mobile phones and gis information. In: Proceedings of the 19th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems, 2011, 54–63
- [25] Nolte M, Kister N, Maurer M. Assessment of deep convolutional neural networks for road surface classification. In: 2018 21st International Conference on Intelligent Transportation Systems (ITSC), 2018, 381–386
- [26] Ramanna S, Sengoz C, Kehler S, et al. Near real-time map building with multi-class image set labelling and classification of road conditions using convolutional neural networks. Applied Artificial Intelligence, 2020, 35: 803-833
- [27] Pamula T. Road traffic conditions classification based on multilevel filtering of image content using convolutional neural networks. IEEE Intelligent Transportation Systems Magazine, 2018, 10(3): 11-21
- [28] 李想. 基于递归神经网络的快速车辆轨迹数据预测: [中国矿业大学硕士论文]. 北京: 中国矿业大学, 2019, 9-29
- [29] 张璐, 柳爽, 田野. 基于卷积和递归神经网络融合的交通状态指数预测. 交通与运输, 2021, 37(01): 91-95
- [30] Wang Chenxing, Luo Haiyong, Zhao Fang, et al. Combining residual and lstm recurrent networks for transportation mode detection using multimodal sensors integrated in smartphones. IEEE Transactions on Intelligent Transportation Systems, 2020, 22: 5473-5485
- [31] He K, Zhang X, Ren S, et al. Identity mappings in deep residual networks. In: European Conference on Computer Vision, 2016, 630–645
- [32] 金涛斌, 卢宇, 徐岩. 基于残差增强门控循环神经网络的交通流量预测技术研究. 现代城市轨道交通, 2023, 2: 84-88
- [33] Brinkhoff T (2000) Generating network-based moving objects. In: Proceedings 12th international conference on scientific and statistica database management, 2000, 253–255
- [34] Daniel K, Jakob E, Michael B, et al. Recent development and applications of sumo-simulation of urban mobility. Int J Adv Syst Meas, 2012, 5:128–138
- [35] Song HY, Baek MS, Sung M. Generating human mobility route based on generative adversarial network. In: 2019 Federated Conference on Computer Science and Information Systems (FedCSIS), 2019, 91-99
- [36] Wu H, Chen Z, Sun W, et al. Modeling trajectories with recurrent neural

- networks. In: International Joint Conference on Artificial Intelligence, 2017, <https://doi.org/10.24963/ijcai.2017%2F430>
- [37] 罗思涵, 杨燕. 一种基于深度学习和元学习的出行时间预测方法. 南京大学学报(自然科学), 2022, 58(4):561-569
- [38] 王飞. 基于出行计划数据的行程时间预测与交通运行状态判别研究: [北京交通大学硕士学位论文]. 北京: 北京交通大学, 2021, 31-56
- [39] 周榆欣, 邬群勇. CLAB模型: 一种乘客出租出行需求短时预测的深度学习模型. 地球信息科学学报, 2023, 25(1): 77-89
- [40] 骈纬国, 吴映波, 陈蒙等. 一种基于时空动态图注意力网络的共享出行需求预测方法. 电子学报, 2022, 50(2): 432-439
- [41] Jiyao An, Liang Guo, Wei Liu, et al. IGAGCN: Information Geometry and Attention Based Spatio-Temporal Graph Convolutional Networks for Traffic Flow Prediction. Neural networks : the official journal of the International Neural Network Society, 2021, 143: 355-367
- [42] 孙加新, 惠飞, 张凯望等. 基于CNN-BiLSTM-AM模型的交通流量预测. 计算机技术与发展, 2023, 33(2): 32-37+43
- [43] Gao, Yuan, Jiandong Zhao, Ziyang Qin, et al. Traffic Speed Forecast in Adjacent Region between Highway and Urban Expressway: Based on MFD and GRU Model. Journal of Advanced Transportation, 2020, <https://doi.org/10.1155/2020%2F8897325>
- [44] 邹国建, 赖子良, 李晔. 基于时空注意力网络的动态高速路网交通速度预测. 计算机工程, 2023, 49(2): 303-313
- [45] Hongjian W, Yu-Hsuan K, Daniel K, et al. A simple baseline for travel time estimation using large-scale trip data. In: Proceedings of the 24th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems, 2015, 61(1-61):4
- [46] Jindal I, Chen X, Nokleby M, et al. A unified neural network approach for estimating travel time and distance for a taxi trip. ArXiv, 2017, abs/1710.04350
- [47] 颜鹏, 郭继峰, 白成超. 考虑移动目标不确定行为方式的轨迹预测方法. 宇航学报, 2022, 43(8): 1040-1051
- [48] 彭子洋, 葛万成. 基于深度神经网络的轨迹预测算法综述. 电视技术, 2022, 46(2): 21-28
- [49] Li Y, Fu K, Wang Z, et al. Multi-task representation learning for travel time estimation. In: Proceedings of the 24th ACM SIGKDD International

- Conference on Knowledge Discovery \& Data Mining, 2018, 1695–1704
- [50] Yuan H, Li G, Bao Z, et al. Effective travel time estimation: when historical trajectories over road networks matter. In: Proceedings of the 2020 ACM SIGMOD International Conference on Management of Data, 2020, 2135–2149
 - [51] Rahmani M, Jenelius E, Koutsopoulos HN (2013) Route travel time estimation using low-frequency floating car data. In: 16th International IEEE Conference on Intelligent Transportation Systems (ITSC 2013), 2013, 2292-2297
 - [52] Wang Y, Zheng Y, Xue Y. Travel time estimation of a path using sparse trajectories. In: Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining, 2014, 25–34
 - [53] 生柳振. 基于ADS-B数据的民航飞机轨迹预测研究: [南京邮电大学硕士论文], 南京: 南京邮电大学, 2022, 23-35
 - [54] 郑志伟, 管雪元, 傅健等. 基于卷积神经网络与长短期记忆神经网络的弹丸轨迹预测. 兵工学报, 2022, 1-9
 - [55] 陶健龙, 王俊雄. 基于对角递归神经网络的AUV非线性 H_∞ 控制. 舰船科学技术, 2022, 44(24): 100-106
 - [56] Saadallah A, Moreira-Matias L, Sousa R, et al. Bright-drift-aware demand predictions for taxi networks. IEEE Transactions on Knowledge and Data Engineering, 2019, 32: 234-245
 - [57] 张永剑. 基于时空图网络的网约车出行需求预测方法研究: [北京交通大学硕士论文]. 北京: 北京交通大学, 2022, 20-35
 - [58] Geng X, Yaguang L, Leye W, et al. Spatiotemporal multi-graph convolution network for ride-hailing demand forecasting. In: AAAI Conference on Artificial Intelligence, 2019, 33:3656–3663
 - [59] Guy L. Traffic flow prediction using adaboost algorithm with random forests as a weak learner. World Academy of Science, Engineering and Technology, International Journal of Mathematical, Computational, Physical, Electrical and Computer Engineering, 2007, 1: 1-6
 - [60] Zhang J, Zheng Y, Qi D. Deep spatio-temporal residual networks for citywide crowd flows prediction. In: AAAI Conference on Artificial Intelligence, 2016, 1655–1661
 - [61] H. Zheng, F. Lin, X. Feng, et al. A Hybrid Deep Learning Model With Attention-Based Conv-LSTM Networks for Short-Term Traffic Flow Prediction. In IEEE Transactions on Intelligent Transportation Systems, 2021,

- 22(11): 6910-6920
- [62] Kumar, Praveen, K. Hariharan. Time Series Traffic Flow Prediction with Hyper-Parameter Optimized ARIMA Models for Intelligent Transportation System. *Journal of Scientific & Industrial Research*, 2022, <https://doi.org/10.56042/jsir.v81i04.50791>
 - [63] Liu, Boyi, Xiangyan Tang, Jieren Cheng, et al. Traffic Flow Combination Forecasting Method Based on Improved LSTM and ARIMA. *Int. J. Embed. Syst*, 2019, 12: 22-30
 - [64] 李青. 基于XGBoost融合模型的交通流量预测技术研究. *自动化仪表*, 2022, 43(12): 123-128
 - [65] Duan, Mindi. Short-Time Prediction of Traffic Flow Based on PSO Optimized SVM. In: 2018 International Conference on Intelligent Transportation, Big Data & Smart City (ICITBS) (2018), 2018, 41-45
 - [66] 伏军霞. 基于图卷积网络的交通流量预测方法的研究: [南京邮电大学硕士学位论文]. 南京: 南京邮电大学, 2022, 22-32
 - [67] Huang, Xiaohui, Yuan Jiang, Jie Tang. MAPredRNN: multi-attention predictive RNN for traffic flow prediction by dynamic spatio-temporal data fusion. *Applied Intelligence*, 2023, <https://doi.org/10.1007/s10489-023-04494-8>
 - [68] 王思超, 汤颖. 结合自相关注意力动态卷积的交通预测网络. *小型微型计算机系统*, 2023, 1-9
 - [69] Feng, Xinxin, Xianyao Ling, Haifeng Zheng, et al. Adaptive Multi-Kernel SVM With Spatial-Temporal Correlation for Short-Term Traffic Flow Prediction. *IEEE Transactions on Intelligent Transportation Systems*, 2019, 20(2019): 2001-2013
 - [70] Wakui, Taku, Takao Kondo, Fumio Teraoka. GAMPAL: an anomaly detection mechanism for Internet backbone traffic by flow size prediction with LSTM-RNN. *Annals of Telecommunications*, 2021, 77(2021): 437-454
 - [71] Jin, Junchen, Dingding Rong, Tong Zhang, et al. A GAN-Based Short-Term Link Traffic Prediction Approach for Urban Road Networks Under a Parallel Learning Framework. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(2022): 16185-16196
 - [72] Pu, Ziyuan, Zhiyong Cui, Jinjun Tang, et al. "Multimodal Traffic Speed Monitoring: A Real-Time System Based on Passive Wi-Fi and Bluetooth Sensing Technology. *IEEE Internet of Things Journal*, 2022, 9(2022):

12413-12424

- [73] Abdelraouf, Amr, Mohamed A. Abdel-At, et al. Utilizing Attention-Based Multi-Encoder-Decoder Neural Networks for Freeway Traffic Speed Prediction. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(2022): 11960-11969
- [74] Zhang, Yu, Peter Tiño, Aleš Leonardis, et al. A Survey on Neural Network Interpretability. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 2020, 5(2020): 726-742
- [75] M. Wu, M. C. Hughes, S. Parbhoo, et al. Beyond sparsity: Tree regularization of deep models for interpretability. In: *AAAI Conference on Artificial Intelligence*, 2017, <https://doi.org/10.1609/aaai.v32i1.11501>
- [76] M. Wu, S. Parbhoo, Michael C. Hughes, et al. Regional tree regularization for interpretability in deep neural networks. In: *AAAI Conference on Artificial Intelligence*, 2020, 6413–6421
- [77] D. Bau, B. Zhou, A. Khosla, et al. Network dissection: Quantifying interpretability of deep visual representations. In: *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, 3319-3327
- [78] B. Zhou, D. Bau, A. Oliva, et al. Interpreting deep visual representations via network dissection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017, 41(9): 2131-2145
- [79] G. Plumb, M. Al-Shedivat, Á. A. Cabrera, et al. Regularizing black-box models for improved interpretability. *ArXiv*, 2019, abs/1902.06787
- [80] E. Weinberger, J. Janizek, S.-I. Lee. Learning deep attribution priors based on prior knowledge. *arXiv: Learning*, 2019
- [81] A. Dhurandhar, P. Chen, R. Luss, et al. Explanations based on the missing: Towards contrastive explanations with pertinent negatives. In: *Neural Information Processing Systems*, 2018
- [82] Y. Wang, H. Su, B. Zhang, et al. Interpret neural networks by identifying critical data routing paths. In: *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018, 8906-8914
- [83] T. Pedapati, A. Balakrishnan, K. Shanmugam, et al. Learning global transparent models consistent with local contrastive explanations. *arXiv: Learning*, 2020, 33
- [84] M. T. Ribeiro, S. Singh, C. Guestrin. Anchors: High-precision model-agnostic explanations. In: *AAAI Conference on Artificial Intelligence*, 2018,

<https://doi.org/10.1609/aaai.v32i1.11491>

- [85] T. Wang. Gaining free or low-cost interpretability with interpretable partial substitute. In: International Conference on Machine Learning, 2019, 6505–6514
- [86] L. Fu. Rule Learning by Searching on Adapted Nets. In: AAAI Conference on Artificial Intelligence, 1991
- [87] K. Odajima, Y. Hayashi, G. Tianxia, et al. Greedy rule generation from discrete data and its use in neural network rule extraction. In: The 2006 IEEE International Joint Conference on Neural Network Proceedings, 2006, 1833-1839
- [88] G. D. Plotkin. A note on inductive generalization. Mathematics, 2008, 5
- [89] K. Simonyan, A. Vedaldi, A. Zisserman. Deep inside convolutional networks: Visualising image classification models and saliency maps. CoRR, 2013, arXiv:1312.6034
- [90] I. Goodfellow, J. Pouget-Abadie, M. Mirza, et al. Generative adversarial nets. NIPS, 2014
- [91] F. Dalvi, N. Durrani, H. Sajjad, et al. What is one grain of sand in the desert? analyzing individual neurons in deep nlp models. In: AAAI Conference on Artificial Intelligence, 2018, 6309–6317
- [92] D. Baehrens, T. Schroeter, S. Harmeling, et al. How to explain individual classification decisions. J. Mach. Learn. Res., 2009, 11: 1803-1831
- [93] M. T. Ribeiro, S. Singh, C. Guestrin. Why should i trust you?: Explaining the predictions of any classifier. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, 1135–1144
- [94] Y. Zheng, Z. Xu, X. Wang. The Fusion of Deep Learning and Fuzzy Systems: A State-of-the-Art Survey. IEEE Transactions on Fuzzy Systems, 2021, 30(8): 2783-2799
- [95] M. Kaur, D. Singh. Fusion of medical images using deep belief networks. Cluster Comput, 2019, 23: 1439-1453
- [96] I. Chaturvedi, R. Satapathy, S. Cavallari, et al. Fuzzy commonsense reasoning for multimodal sentiment analysis. Pattern Recognit. Lett., 2019, 125: 264-270
- [97] H. J. Sadaei, de Lima e Silva, P.C., et al. Short-term load forecasting by using a combined method of convolutional neural networks and fuzzy time series.

- Energy, 2019, 175: 365–377
- [98] R. He, X. Li, G. Chen, et al. Generative adversarial network-based semi-supervised learning for real-time risk warning of process industries. *Expert Syst. Appl.*, 2020, 150: 113244
 - [99] N. Tak, A. A. Evren, M. Tez, et al. Recurrent type-1 fuzzy functions approach for time series forecasting. *Applied Intelligence*, 2017, 48: 68–77
 - [100] I. Qasim, M. Alam, S. Khan, et al. A comprehensive review of type-2 fuzzy ontology. *Artificial Intelligence Review*, 2019, 53: 1187-1206
 - [101] M. Gheisarnejad, J. Boudjadar, M. H. Khooban. A new adaptive type-II fuzzy-based deep reinforcement learning control: Fuel cell airfeed sensors control. *IEEE Sensors Journal*, 2019, 19(20): 9081-9089
 - [102] H. Hermessi, O. Mourali, E. Zagrouba. Deep feature learning for soft tissue sarcoma classification in MR images via transfer learning. *Expert Syst. Appl.*, 2019, 120: 116–127
 - [103] R. S. T. Lee. Chaotic type-2 transient-fuzzy deep neuro-oscillatory network (CT2TFDNN) for worldwide financial prediction. *IEEE Transactions on Fuzzy Systems*, 2019, 28(4): 731-745
 - [104] D. Qiu, H. H. Jiang, S. Q. Chen. Fuzzy information retrieval based on continuous bag-of-words model. *Symmetry*, 2020, 12: 225
 - [105] R. A. Aliev, B. Fazlollahi, R.R. Aliev, et al. Linguistic time series forecasting using fuzzy recurrent neural network. *Soft Computing*, 2008, 12: 183–190
 - [106] Y. Wen, F. O. Rodriguez, M. A. Moreno-Armendariz. Hierarchical fuzzy CMAC for nonlinear systems modeling,” *IEEE Transactions on Fuzzy System*, 2008, 16(5): 1302–1314
 - [107] D. R. Wu, Y. Y e, J. Huang, et al. Optimize TSK fuzzy systems for regression problems: Minibatch gradient descent with regularization, dropRule, and adaBound (MBGD-RDA). *IEEE Transactions on Fuzzy Systems*, 2019, 28(5): 1003-1015
 - [108] G. Manogaran, R. V aratharajan, M. K. Priyan. Hybrid recommendation system for heart disease diagnosis based on multiple kernel learning with adaptive neuro-fuzzy inference system. *Multimedia Tools and Applications*, 2017, 77: 4379-4399
 - [109] Khan, Asifullah, Anabia Sohail, Umme Zahoora, et al. A survey of the recent architectures of deep convolutional neural networks. *Artificial Intelligence Review*, 2019, 53(2019): 5455-5516

- [110] Y. LeCun, B. E. Boser, J. S. Denker, et al. Backpropagation Applied to Handwritten Zip Code Recognition. *Neural Computation*, 1989, 1(4): 541-551
- [111] 余昉恒. 循环神经网络门结构模型研究: [浙江大学硕士论文]. 浙江: 浙江大学, 2018, 19-26
- [112] 李一波, 郭培宜, 张森悦. 深度卷积神经网络中激活函数的研究. *计算机技术与发展*, 2021, 31(09): 61-66
- [113] Sharma, Robin Kumar, Marc Casas. Task-based Acceleration of Bidirectional Recurrent Neural Networks on Multi-core Architectures. In: 2022 IEEE International Parallel and Distributed Processing Symposium (IPDPS) (2022), 2022, 941-951
- [114] Zhan, Tao, Maoguo Gong, Xiangming Jiang, et al. Transfer Learning-Based Bilinear Convolutional Networks for Unsupervised Change Detection. *IEEE Geoscience and Remote Sensing Letters*, 2022, 19 (2022): 1-5
- [115] Wang, Zhengcun, Chuanbo Wen, Yifan Dong. A method for rolling bearing fault diagnosis based on GSC-MDRNN with multi-dimensional input. *Measurement Science and Technology*, 2023, 34 (2023): n. pag
- [116] Mahjoub, S. El, L. Chrifi-Alaoui, et al. Predicting Energy Consumption Using LSTM, Multi-Layer GRU and Drop-GRU Neural Networks. *Sensors (Basel, Switzerland)*, 2022, 22 (2022): n. pag
- [117] 王延达, 陈炜通, 皮德常等. 一种自适应记忆神经网络多跳读取与覆盖度机制结合的药物推荐模型. *电子学报*, 2022, 50(04): 943-953
- [118] 杨文玲, 广晓平. 基于PSO-LSTM的高速公路短时交通流预测研究. *综合运输*, 2023, 1-7
- [119] Li, G., Matthias Müller, Ali K. Thabet, et al. DeepGCNs: Can GCNs Go As Deep As CNNs?”. In: 2019 IEEE/CVF International Conference on Computer Vision (ICCV) (2019), 2019, 9266-9275
- [120] Kasai, Jungo, Hao Peng, et al. Finetuning Pretrained Transformers into RNNs. *ArXiv*, 2021, abs/2103.13076 (2021): n. pag
- [121] 杨国田, 王英男, 谢锐彪等. 基于随机子空间的集成深度信念网络算法. *控制工程*, 2023, 30(01): 1-7
- [122] X. Li, C. Cao, Y. Shi, et al. A Survey of Data-driven and Knowledge-aware eXplainable AI. *IEEE Transactions on Knowledge and Data Engineering*, 2020, 34(99): 1-1
- [123] L. Breiman. Random forests. *Machine Learning*, 2001, 45(1): 5–32
- [124] D. Erhan, Y. Bengio, A. C. Courville, et al. Visualizing higher-layer features

- p>of a deep network. Univ. Montreal, 2009, 1341(3): 1-1
- [125] M. O. Riedl. Human-centered artificial intelligence and machine learning. ArXiv, 2019, 1(1): 33-36
 - [126] C. J. Cai, E. Reif, N. Hegde, et al. Human-centered tools for coping with imperfect algorithms during medical decision-making. In: Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems, 2019, <https://doi.org/10.1145/3290605.3300234>
 - [127] U. Ehsan, P. Tambwekar, L. Chan, et al. Automated rationale generation: A technique for explainable AI and its effects on human perceptions. In: Proceedings of the 24th International Conference on Intelligent User Interfaces, 2019, 263–274
 - [128] B. Harrison, U. Ehsan, M. O. Riedl. Guiding reinforcement learning exploration using natural language. ArXiv, 2018, 1956–1958
 - [129] U. Ehsan, P. Tambwekar, L. Chan, et al. Learning to generate natural language rationales for game playing agents. AIIDE Workshops, 2018
 - [130] L. A. Zadeh. Fuzzy sets. Inf. Control, 1996, 8: 338-353
 - [131] L. A. Zadeh. Fuzzy Logic and Its Application to Approximate Reasoning. Information Processing, 1974
 - [132] W. Guan. A summary of traffic flow forecasting methods. Journal of Highway and Transportation Research and Development, 2004, 21(3): 82–85
 - [133] M. S. Ahmed, A. R. Cook. Analysis of freeway traffic time-series data by using Box-Jenkins techniques. Transportation Research Record, 1979, 1-9
 - [134] A. J. Smola, B. Schölkopf. A tutorial on support vector regression. Statistics and Computing, 2004, 14(3): 199–222
 - [135] L. Zhao, Y. Song, C. Zhang, et al. T-GCN: A Temporal Graph Convolutional Network for Traffic Prediction. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(9): 3848-3858
 - [136] J. Zhu, Q. Wang, C. Tao, et al. AST-GCN: Attribute-Augmented Spatiotemporal Graph Convolutional Network for Traffic Forecasting. IEEE Access, 2021, 9: 35973-35983

附录 A （攻读硕士学位期间发表的学术论文目录）

- [1] 安吉尧, 钱欣姣, 赵谨, 刘清钦, 陈佳丽. 一种基于模糊理论的可解释交通认知方法: 中国, 发明专利, 202211453961.9. (第二作者)
- [2] Ji Yao An, Xinjiao Qian, Lihua Zhu, Jiali Chen, Jin Zhao, Qingqin Liu. ExFuzzGCN: An interpretable and expressive fuzzy-based GCN for Intelligent Traffic Cognition. NN, NEUNET-D-23-00747. (SCI 期刊, 已投稿, 第二作者)
- [3] Ji Yao An, Jin Zhao, Qingqin Liu, Xinjiao Qian, Jiali Chen. Self-Constructed Deep Fuzzy Neural Network for Traffic Flow Prediction, Electronics, electronics-2278047. (SCI 期刊, 已接受, 第四作者)

附录 B （攻读硕士学位期间参与项目目录）

- [1] 面向智能交通认知的 CPS 计算架构与可解释深度学习模型研究, 国家自然科学基金面上项目. 项目编号: 62172147.
- [2] 国家自然科学基金面上项目, National Natural Science Foundation of China, 62172147.
- [3] 湖南省自然科学基金面上项目, Natural Science Foundation of Hunan Province, China, 2018JJ2063.
- [4] 湖南省财政厅高校改革发展基金项目, University Innovation and Development Foundation of Hunan Provincial Department of Finance.

致 谢

提笔至此，我竟不知道该从何说起。硕士研究生大概率是我这一生取得的最高学历了，回想起这二十年的漫漫求学路，有太多太多值得感谢的人和事。

哀哀父母，生我劬劳。我的母亲总说我们家是靠我父亲的肩膀背出来的。他年轻的时候力壮如牛，十二三岁就在外面捡废品，抬过盖房子的水泥板，打过混泥土，近几年又当起了地地道道的农民。母亲则当起了父亲的辅助，除了在工厂里上班以外还会在父亲忙不过来的时候帮帮他。我以前只觉得心疼他们，一有时间就帮父母分担一些。近几年看着父亲承包的土地越来越多，越来越像一个种地“专家”，不由得又多出了几分敬佩之情。都说父母是孩子的第一任老师，但其实也是孩子终身的导师。虽然我的父母都只接受过几年的教育，但他们总能在我的关键时刻给我启迪和动力。千言万语都道不尽父母的恩情，只愿自己能变得更强大些，成为他们余生的依靠。

淳淳如父语，殷殷似友亲。在求学路上，遇到过不少良师，他们在我人生的不同阶段给予了我帮助和指导。研究生阶段，我最想感谢的就是我的导师，安吉尧教授。我和同门们总是用和蔼来形容安老师，因为安老师从来都不会给我们很大的压力，只会在我们可能会松懈的时候提点我们。安老师治学严谨，紧跟时代发展进行研究创新，当我在科研的大海里迷航时，为我指明了方向。在生活上，我也受到了安老师不少的关照。老师经常叮嘱我们多出去运动运动，锻炼好身体，在疫情期间也能经常收到安老师温暖的问候。作为安老师的学生，我感到很荣幸也很幸运。

人生贵相知，何用金与钱。我是一个慢热且不擅长维系关系的人，读研前积累的，到现在还有联系的朋友不过四五个。很幸运的是，读研期间我遇到了一群活泼可爱善良大方的同门——陈佳丽、刘清钦、赵谨、方菊、张璇、蒲朝辉、张播、蔡禧宝、Sohel Rana、Siyamoy Ghory，还有已经毕业的师兄师姐们——付志强、刘韦、郭亮、任平。她们不仅是和我一起讨论问题的同学，更是相互关心帮助的朋友。还有我的室友们——梁小茜、卫小琼、蒋昕、李虹宇、陈钰芳，感谢她们为我的研究生生活增添了不少乐趣与欢笑。

天行健，君子以自强不息。至此，我的学生生涯仅剩短短的两三个月时间，回想起过往的点点滴滴，竟开始有些不舍。最后，我还想感谢一下在无数艰难时刻坚持下去的自己，希望自己步入社会以后也能带着这股子冲劲和韧劲，勇攀人生的高峰。

钱欣姣

2023年4月